

[Logo IUT d'Avignon]

[Logo BUT Science des Données]

SAE 4-02 — SITUATION D'APPRENTISSAGE ET D'ÉVALUATION

Analyses Multivariées

du Catalogue Automobile

Forza Horizon 5

ACP — AFC — CAH — ACM

Réduction de dimension, classification et analyse des associations

Étudiant : Ngaleu Trésor

Formation : BUT Science des Données — 2^{ème} Année EMS

Établissement : IUT d'Avignon — Université d'Avignon

Année universitaire : 2025–2026

Logiciels utilisés : R (FactoMineR, factoextra, ggplot2) et SAS Studio

*Ce rapport présente une démarche complète d'analyse multivariée appliquée
au catalogue de véhicules du jeu vidéo Forza Horizon 5.*

May 29, 2026

SAE 4-02 — Analyses Multivariées

Ngaleu Trésor

2025–2026

Contents

1	Introduction Générale	2
1.1	Présentation du projet	2
1.2	Problématique	2
1.3	Plan du rapport	2
2	Préparation des données	3
2.1	Pourquoi cette étape est importante	3
2.2	Décisions de nettoyage	3
3	Analyse en Composantes Principales (ACP)	4
3.1	Pourquoi utiliser l'ACP ?	4
3.2	Principe de la méthode	4
3.3	Variables utilisées	4
3.4	Résultat préliminaire — Nuage de points multivarié	5
3.5	Résultat 1 — Combien d'axes retenir ?	6
3.6	Résultat 2 — Quelles variables contribuent à chaque axe ?	7
3.7	Résultat 3 — Contributions des variables	9
3.8	Résultat 4 — Positionnement des véhicules individuels	10
3.9	Résultat 5 — Vue d'ensemble par famille de véhicules	11
3.10	Résultat 6 — Biplot : variables et individus ensemble	12
3.11	Conclusion de l'ACP	12
4	Analyse Factorielle des Correspondances (AFC)	13
4.1	Pourquoi utiliser l'AFC ?	13
4.2	Principe de la méthode	13
4.3	Variables choisies et justification	13
4.4	Test du chi-deux — Les deux variables sont-elles liées ?	13
4.5	Résultat 1 — Vue d'ensemble des profils	14
4.6	Résultat 2 — Inertie des axes de l'AFC	15
4.7	Résultat 3 — Plan factoriel principal	16
4.8	Résultat 4 — Projection du type de transmission	17
4.9	Conclusion de l'AFC	17
5	Classification Hiérarchique Ascendante (CAH) — SAS	18

5.1	Pourquoi utiliser la CAH ?	18
5.2	Principe de la méthode de Ward	18
5.3	Préparation des données pour la CAH	18
5.4	Résultat 1 — Choix du nombre de classes	19
5.5	Résultat 2 — Le dendrogramme	20
5.6	Résultat 3 — Profil des 3 clusters	21
5.7	Conclusion de la CAH	21
6	Analyse des Correspondances Multiples (ACM) — SAS	22
6.1	Pourquoi utiliser l'ACM ?	22
6.2	Différence avec l'AFC	22
6.3	Principe de la méthode	22
6.4	Préparation : discrétisation des variables	22
6.5	Résultat 1 — Plan factoriel des modalités	24
6.6	Résultat 2 — Classification des modalités	25
6.7	Résultat 3 — Cohérence avec l'ACP et la CAH	26
6.8	Conclusion de l'ACM	26
7	Conclusion Générale	27
7.1	Synthèse des résultats	27
7.2	Réponse à la problématique	27
7.3	Limites de l'étude et perspectives	27
8	Annexes	29
8.1	Annexe A — Code R complet	29
8.2	Annexe B — Code SAS complet	31
8.3	Annexe C — Tableau récapitulatif des méthodes	34

1 Introduction Générale

1.1 Présentation du projet

Ce rapport s'inscrit dans le cadre de la SAE 4-02 (*Situation d'Apprentissage et d'Évaluation*) de deuxième année de BUT Science des Données. L'objectif est d'appliquer des méthodes d'**analyse multivariée** à un jeu de données réel pour en comprendre les structures profondes, identifier des groupes cohérents et révéler des associations entre variables.

Le jeu de données étudié provient du jeu vidéo **Forza Horizon 5**, un jeu de course développé par Playground Games et édité par Xbox Game Studios, sorti en 2021. Ce jeu propose plus de 500 véhicules réels soigneusement modélisés — des citadines aux hypercars en passant par des tout-terrains et des camions de compétition. L'ensemble de données a été mis à disposition librement sur la plateforme **Kaggle** (auteur : deepcontractor, licence CC0 — Domaine public, score d'utilisabilité : 10/10).

Il recense **539 véhicules** décrits par **22 variables**, réparties en quatre grandes familles :

Dimension	Variables principales
Identité	Nom du modèle, année de fabrication
Performances	Vitesse, maniabilité, accélération, freinage, départ, tout-terrain
Caractéristiques techniques	Puissance (chevaux), note globale, poids
Économie & Profil	Prix en crédits, catégorie, type de transmission, mode d'obtention

Ce jeu de données est particulièrement riche car il mêle des variables numériques fortement corrélées entre elles (les scores de performance) et des variables qualitatives structurantes (catégorie, transmission, source d'obtention). Il constitue donc un terrain idéal pour mettre en œuvre les méthodes d'analyse multivariée.

1.2 Problématique

La question centrale de cette étude est la suivante :

Quels sont les grands profils de véhicules qui structurent le catalogue de Forza Horizon 5, et quelles associations peut-on détecter entre les caractéristiques techniques, les catégories de véhicules et les modes d'acquisition dans le jeu ?

1.3 Plan du rapport

Pour répondre à cette question, quatre méthodes sont mobilisées de façon complémentaire :

- **ACP** (sous R) : résumer les variables de performance en quelques dimensions interprétables.
- **AFC** (sous R) : explorer les liens entre catégories de véhicules et modes d'obtention.
- **CAH** (sous SAS) : segmenter les véhicules en groupes homogènes.
- **ACM** (sous SAS) : analyser simultanément plusieurs variables qualitatives pour révéler des profils multidimensionnels.

2 Préparation des données

2.1 Pourquoi cette étape est importante

Avant toute analyse statistique, il est indispensable de s'assurer que les données sont **propres, cohérentes et exploitables**. Dans notre cas, le jeu de données brut présentait plusieurs problèmes à corriger : des valeurs numériques stockées sous forme de texte avec des unités (par exemple "155 Mph", "6.2s"), des valeurs inconnues codées "info_not_found", et des colonnes avec trop de données manquantes pour être utilisables.

2.2 Décisions de nettoyage

Les étapes de préparation réalisées sont les suivantes :

1. **Remplacement des valeurs inconnues** : toutes les entrées "info_not_found" ont été remplacées par des valeurs manquantes (NA).
2. **Conversion des types** : les variables numériques stockées en texte (vitesse maximale, temps au 0-60 mph, force g) ont été converties après suppression des unités.
3. **Suppression des colonnes trop lacunaires** : les variables Top_Speed, g.force, X0.60_Mph, X0.100_Mph et car_source_2 ont été supprimées car elles présentaient plus de 70 % de valeurs manquantes.
4. **Extraction de l'année et du modèle** : la variable Name_and_model a été décomposée pour créer les colonnes Year (année de fabrication) et Model (nom du modèle).
5. **Imputation par la médiane** : les 37 valeurs manquantes restantes sur Horse_Power (6,9 % de l'effectif) ainsi que celles des autres variables quantitatives ont été imputées par la médiane (375 chevaux pour Horse_Power), méthode robuste aux valeurs extrêmes des hypercars. La variable qualitative présentant de rares valeurs manquantes a été supprimée (suppression des lignes concernées).

3 Analyse en Composantes Principales (ACP)

3.1 Pourquoi utiliser l'ACP ?

Lorsqu'on étudie un jeu de données contenant plusieurs variables numériques, il est fréquent que ces variables soient fortement corrélées entre elles. Par exemple, un véhicule puissant a en général un bon score de vitesse, un bon score d'accélération et une bonne note globale. Analyser chaque variable séparément est donc redondant.

L'**Analyse en Composantes Principales (ACP)** résout ce problème : elle regroupe les informations contenues dans les 10 variables quantitatives en un petit nombre de **dimensions synthétiques** appelées composantes principales. Chaque composante résume une partie de l'information originale, sans perdre trop de précision.

Concrètement, l'ACP permet ici de répondre à la question : *quelles sont les grandes dimensions qui différencient les véhicules du catalogue Forza Horizon 5 ?*

3.2 Principe de la méthode

L'ACP travaille sur des données **centrées et réduites** : chaque variable est ramenée à une moyenne de 0 et un écart-type de 1, ce qui évite qu'une variable exprimée dans de grandes unités (comme le prix en crédits) domine artificiellement les résultats.

Elle calcule ensuite les directions dans lesquelles les données varient le plus. Ces directions sont les **composantes principales**, définies mathématiquement par les vecteurs propres de la matrice de corrélation :

$$\mathbf{R} \mathbf{v}_k = \lambda_k \mathbf{v}_k$$

où λ_k est la **valeur propre** de l'axe k , qui mesure la quantité de variance capturée par cet axe. Le pourcentage de variance expliquée est :

$$\tau_k = \frac{\lambda_k}{\sum_j \lambda_j} \times 100$$

La **qualité de représentation** d'une variable sur un axe est mesurée par le $\cos^2$ (proche de 1 = bien représentée) et sa **contribution** indique à quel point elle a participé à la construction de cet axe.

3.3 Variables utilisées

Les 10 variables quantitatives suivantes ont été utilisées comme variables actives dans l'ACP :

Variable	Description
Horse_Power	Puissance du moteur en chevaux
Stock_Rating	Note globale du véhicule attribuée par le jeu
speed	Score de vitesse de pointe
handling	Score de maniabilité en virage
acceleration	Score d'accélération
launch	Score de départ (reprise depuis l'arrêt)

Variable	Description
braking	Score de freinage
Offroad	Score de comportement en tout-terrain
In_Game_Price	Prix d'achat en crédits du jeu
Weight_lbs	Poids du véhicule à vide (en livres)

Les variables qualitatives (`Model_type`, `Drive_Type`, `car_source`) sont exclues des variables actives car l'ACP ne fonctionne que sur des données numériques. Elles seront utilisées en illustration pour enrichir l'interprétation.

3.4 Résultat préliminaire — Nuage de points multivarié

Avant d'appliquer l'ACP, il est essentiel d'explorer visuellement les relations entre toutes les variables quantitatives. Le **nuage de points multivarié** permet de détecter à l'œil les corrélations, les tendances non linéaires et les valeurs atypiques.




Figure 1: Nuage de points multivarié — Relations bivariées entre les 10 variables quantitatives

3.5 Résultat 1 — Combien d'axes retenir ?




Figure 2: Éboulis des valeurs propres — Règle de Kaiser (valeur propre > 1)

Lecture du graphique : Ce graphique (appelé *éboulis* ou *scree plot*) représente la valeur propre de chaque axe, du plus informatif au moins informatif. La **règle de Kaiser** recommande de ne retenir que les axes dont la valeur propre dépasse 1, ce qui signifie qu'ils apportent plus d'information qu'une seule variable originale.

Ici, **3 axes franchissent ce seuil :**

Axe	Valeur propre	Variance capturée	Cumulé
Dim. 1	5,55	55,5 %	55,5 %
Dim. 2	1,46	14,6 %	70,1 %
Dim. 3	1,02	10,2 %	80,2 %

Ces trois axes ensemble capturent **80,2 % de l'information totale** contenue dans les 10 variables initiales. Autrement dit, on résume 10 variables en 3 dimensions sans perdre grand-chose.

3.6 Résultat 2 — Quelles variables contribuent à chaque axe ?




Figure 3: Cercle des corrélations — Plan Dim.1 x Dim.2 (70 % de la variance)

Lecture du graphique : Le cercle des corrélations représente chaque variable comme une flèche. Plus la flèche est **longue**, mieux la variable est représentée sur ce plan. Les flèches qui pointent dans la **même direction** indiquent des variables fortement corrélées entre elles. Les flèches qui pointent dans des **directions opposées** indiquent des variables qui s'opposent.

- **Axe 1 (55,5 % de la variance)** — c'est l'axe de la **performance sur route**. Les variables **speed**, **handling**, **acceleration**, **launch**, **braking**, **Horse_Power** et **Stock_Rating** pointent toutes vers la droite avec des flèches longues. Cela signifie qu'elles sont très corrélées entre elles : un véhicule puissant est aussi rapide, maniable et bien noté. Un véhicule situé à droite sur cet axe est donc un véhicule haute performance.
- **Axe 2 (14,6 % de la variance)** — c'est l'axe du **gabarit et du tout-terrain**. Les variables **Weight_lbs** (poids) et **Offroad** (tout-terrain) pointent vers le haut. Cela signifie que les véhicules lourds sont souvent ceux qui ont les meilleurs scores tout-terrain, comme les SUV et les camions. En bas, on retrouve les véhicules légers de route.




Figure 4: Cercle des corrélations — Plan Dim.1 x Dim.3 (65,7 % de la variance)

Lecture du graphique : Ce second plan factoriel révèle le rôle de la variable `In_Game_Price` (prix en crédits). Sa flèche pointe presque verticalement, séparée des autres variables. Cela indique que le **prix est totalement indépendant des performances** : une voiture peut être très chère sans être la plus rapide, simplement parce qu'elle est rare ou historiquement célèbre. C'est l'axe 3.

- **Axe 3 (10,2 % de la variance)** — c'est l'axe de la **valeur de collection et de la rareté**. Il est défini presque exclusivement par le prix en crédits (contribution de 73,6 %). Les véhicules en haut de cet axe sont des modèles très chers, non pas parce qu'ils sont les plus performants, mais parce qu'ils sont rares, iconiques ou historiques (Ferrari 250 GTO, Ford GT40, etc.).

3.7 Résultat 3 — Contributions des variables




Figure 5: Contributions des variables à l'Axe 1 — performance sur route

Lecture du graphique : Ce graphique montre, pour chaque variable, quelle proportion elle apporte dans la construction de l'axe 1. La ligne rouge correspond au seuil d'une contribution égale pour toutes les variables (10 % si on avait 10 variables équiréparties).

Toutes les variables de performance (**braking**, **handling**, **acceleration**, **speed**, **launch**, **Stock_Rating**, **Horse_Power**) contribuent de façon quasi équivalente (entre 11 % et 16 %). Cela confirme qu'elles mesurent toutes la même réalité sous-jacente : la performance globale du véhicule. En revanche, **Weight_lbs**, **Offroad** et **In_Game_Price** contribuent très peu à cet axe : ce ne sont pas des variables de performance sur route.




Figure 6: Contributions des variables à l'Axe 2 — gabarit et tout-terrain

Lecture du graphique : L'axe 2 est dominé presque exclusivement par **Weight_lbs** (44 % de contribution) et **Offroad** (33 %). Ces deux variables définissent à elles seules les trois quarts de cet axe. Toutes les autres variables n'y contribuent que de façon marginale. Cela confirme que l'axe 2 oppose les véhicules lourds et tout-terrain aux véhicules légers de route.

3.8 Résultat 4 — Positionnement des véhicules individuels




Figure 7: Véhicules les mieux représentés sur le plan Dim.1 x Dim.2 — colorés par qualité de représentation

Lecture du graphique : Chaque point représente un véhicule. La couleur indique la qualité de représentation : plus le point est foncé (bleu foncé), mieux le véhicule est représenté sur ce plan et plus son positionnement est fiable. Les points clairs sont moins bien représentés et doivent être interprétés avec prudence.

On identifie clairement **quatre zones** sur ce graphique :

1. **Droite du graphique** (Dim.1 élevée) : les **hypercars et supercars** — Lamborghini Aventador, Audi R8, Porsche Carrera GT. Ce sont les véhicules les plus performants du catalogue.
2. **Haut gauche** (Dim.2 élevée, Dim.1 faible) : les **tout-terrain lourds** — Jeep Gladiator, Hummer H1. Lourds et adaptés au tout-terrain, mais peu performants sur route.
3. **Bas droite** (Dim.1 élevée, Dim.2 faible) : les **sportives légères historiques** — Saleen S7, Toyota 2000GT. Très performantes sur asphalte mais légères.
4. **Bas gauche** (Dim.1 et Dim.2 faibles) : les **citadines et classiques modestes** — Volkswagen Golf GTi Mk2, Chevrolet Bel Air. Performances limitées, usage quotidien ou collection.

3.9 Résultat 5 — Vue d'ensemble par famille de véhicules




Figure 8: Plan factoriel coloré par famille de véhicules — positionnement des groupes

Lecture du graphique : Ce graphique regroupe les véhicules par famille et permet de voir si les familles se séparent bien dans l'espace factoriel. On observe :

- Les **Supercars/GT** (violet) sont concentrées sur la droite de l'axe 1 : ce sont effectivement les véhicules les plus performants.
- Les **Tout-terrain** (bleu clair) se distribuent en haut gauche : gabarits lourds, peu performants sur route.
- Les **Classiques/Retro** (rouge) se regroupent en bas gauche : véhicules anciens, aux performances modestes selon les standards actuels.
- Les **Sports/Hot Hatch** (bleu foncé) et **Muscle/Track** (vert) occupent des positions intermédiaires, reflétant leur polyvalence.

Cette séparation spatiale confirme que les familles définies dans le jeu correspondent bien à des profils statistiques distincts et cohérents.

3.10 Résultat 6 — Biplot : variables et individus ensemble




Figure 9: Biplot ACP — Superposition des variables (flèches) et des véhicules (points)

Lecture du graphique : Le biplot superpose sur le même plan les variables (flèches rouges) et les véhicules (points gris). Il permet de voir directement quels véhicules ressemblent à quelles variables. Un véhicule situé dans la direction d'une flèche a une valeur élevée pour cette variable.

On voit par exemple que les **Lamborghini** et **Porsche** se trouvent dans la direction des flèches de performance (**speed**, **braking**, **Horse_Power**). À l'inverse, les véhicules proches de la flèche **Weight_lbs** sont les camions et SUV. Les véhicules rares et chers (Ferrari classiques, Ford GT40) se trouvent dans la direction de la flèche **In_Game_Price**.

3.11 Conclusion de l'ACP

L'ACP a permis de résumer les 10 variables quantitatives du catalogue en **3 dimensions interprétables** qui capturent 80 % de l'information :

- **Dimension 1 :** la **performance sur route** — elle sépare les hypercars des véhicules modestes.
- **Dimension 2 :** le **gabarit et le tout-terrain** — elle sépare les mastodontes lourds des sportives légères.
- **Dimension 3 :** la **valeur de collection** — elle révèle que le prix est indépendant des performances.

Ces trois axes fournissent un cadre de lecture du catalogue que les analyses suivantes vont enrichir et confirmer.

4 Analyse Factorielle des Correspondances (AFC)

4.1 Pourquoi utiliser l'AFC ?

Après avoir analysé les variables numériques avec l'ACP, il est naturel de s'intéresser aux variables qualitatives. En particulier, une question se pose : **existe-t-il des liens entre la catégorie d'un véhicule et la façon dont on peut l'obtenir dans le jeu ?**

Par exemple, les hypercars sont-elles plus souvent réservées aux récompenses spéciales ? Les voitures classiques sont-elles liées aux “barn finds” ? Pour répondre à ces questions, on utilise l'**Analyse Factorielle des Correspondances (AFC)**.

L'AFC est la méthode adaptée lorsqu'on dispose de **deux variables qualitatives** et qu'on souhaite visualiser sur un plan graphique les associations entre leurs modalités.

4.2 Principe de la méthode

L'AFC part d'un **tableau de contingence** : un tableau qui croise les deux variables et indique combien de véhicules appartiennent à chaque combinaison de modalités. Elle mesure ensuite les écarts entre ce tableau et ce qu'on observerait si les deux variables étaient totalement indépendantes.

L'écart global est mesuré par le **chi-deux** :

$$\chi^2 = \sum_i \sum_j \frac{(n_{ij} - \hat{n}_{ij})^2}{\hat{n}_{ij}}$$

où n_{ij} est l'effectif observé et $\hat{n}_{ij}$ l'effectif attendu sous l'hypothèse d'indépendance.

L'AFC produit ensuite un plan factoriel où chaque catégorie est représentée par un point. **Deux points proches indiquent une association forte** : les véhicules de ces catégories ont tendance à être obtenus de la même façon.

4.3 Variables choisies et justification

- **Variable lignes** : `Model_type` — la catégorie du véhicule dans le jeu (38 modalités : hypercars, muscle, rally, offroad, etc.).
- **Variable colonnes** : `car_source` — le mode d'obtention dans le jeu (6 modalités : Autoshow, Barn Find, Season Event, Wheelspin, Accolade, etc.).

Ce choix est justifié par la logique du jeu : certains types de véhicules sont naturellement liés à des mécaniques d'obtention particulières. Visualiser ces associations permet de comprendre la structure économique et narrative du jeu.

`Drive_Type` (type de transmission) sera utilisé comme **variable illustrative** : elle sera projetée sur le plan sans participer à sa construction, pour enrichir l'interprétation.

4.4 Test du chi-deux — Les deux variables sont-elles liées ?

Avant de lancer l'AFC, on teste statistiquement si les deux variables sont liées. L'hypothèse nulle est : *“la catégorie du véhicule et son mode d'obtention sont indépendants”*.

Test du chi-deux d'indépendance

Statistique chi2 : 327.79

Degres de liberte : 296

p-value : 0.0986

La p-value obtenue ($p = 0,099$) est légèrement supérieure au seuil classique de 5 %. On ne peut pas rejeter formellement l'hypothèse d'indépendance. Cependant, cette valeur proche de 0,10 sur un grand tableau (38 lignes $\times$ 6 colonnes) suggère que **des tendances réelles existent**, simplement masquées par la petite taille de certaines cellules. L'AFC sera donc conduite dans une **optique exploratoire**.

4.5 Résultat 1 — Vue d'ensemble des profils




Figure 10: Carte de chaleur des profils — Proportion de chaque mode d'obtention au sein de chaque catégorie

Lecture du graphique : Cette carte de chaleur est le point de départ de l'AFC. Chaque ligne correspond à une catégorie de véhicule, chaque colonne à un mode d'obtention. La couleur indique la proportion : bleu foncé = ce mode d'obtention est dominant pour cette catégorie.

On remarque immédiatement que **l'Autoshow domine presque partout** (colonne de gauche très foncée pour la majorité des lignes). C'est le mode d'obtention standard : la plupart des voitures s'achètent simplement au catalogue du jeu. Mais on distingue aussi quelques cellules foncées pour les autres colonnes, révélant des associations spécifiques que l'AFC va formaliser.

4.6 Résultat 2 — Inertie des axes de l'AFC




Figure 11: Valeurs propres de l'AFC — Inertie expliquée par chaque axe

Lecture du graphique : En AFC, les valeurs propres mesurent l'*inertie*, c'est-à-dire la quantité d'association entre les deux variables capturée par chaque axe. Contrairement à l'ACP où les valeurs propres peuvent être élevées, en AFC elles sont naturellement faibles (ici le maximum est environ 0,07) : c'est normal et attendu.

Les deux premiers axes capturent ensemble **48,5 % de l'inertie totale**, ce qui est suffisant pour une lecture exploratoire fiable. Les 5 axes représentent à eux seuls 89,7 % de l'inertie.

4.7 Résultat 3 — Plan factoriel principal




Figure 12: Plan factoriel AFC — Associations entre catégories (bleu) et modes d'obtention (rouge)

Lecture du graphique : Sur ce plan, les points proches sont associés. Un point bleu (catégorie) proche d'un point rouge (mode d'obtention) signifie que les véhicules de cette catégorie sont fréquemment obtenus de cette façon.

- **Axe 1 (26,1 %) — l'axe de l'exclusivité temporelle :** il sépare les véhicules liés aux *Season Events* (récompenses saisonnières, valables uniquement pendant des fenêtres de temps limitées) des véhicules à accès permanent. Les *Cult Classics* (CULTCL) apparaissent clairement associés aux *Season Event*. Ce sont des véhicules iconiques et rares que les développeurs réservent aux récompenses limitées pour créer un sentiment d'urgence chez le joueur.
- **Axe 2 (22,4 %) — l'axe de la progression du joueur :** il isole les catégories atypiques (TRACT = tracteurs de compétition, RALLM = Rally Monsters) qui s'obtiennent via les mécaniques de récompense de progression (Accolade, Wheelspin). Ce sont des véhicules "cadeaux" que le jeu offre au joueur pour récompenser sa progression, pas des véhicules qu'on achète.

4.8 Résultat 4 — Projection du type de transmission




Figure 13: Plan AFC enrichi — Type de transmission projeté en éléments supplémentaires (orange)

Lecture du graphique : Les points orange représentent les types de transmission (FWD = traction avant, RWD = propulsion arrière, AWD = quatre roues motrices) projetés sur le plan sans influencer sa construction. Leur position révèle leur proximité avec certaines catégories et certains modes d'obtention.

- Le **RWD** (propulsion arrière) se positionne du côté des catégories vintage et des modes d'obtention alternatifs. Ce résultat est cohérent : les voitures anciennes (avant les années 1980) étaient majoritairement à propulsion arrière, et ces modèles sont souvent obtenus de façon non standard.
- L'**AWD** (quatre roues motrices) se rapproche de l'Autoshow et des catégories sportives modernes. Les sportives contemporaines équipées de l'AWD sont disponibles à l'achat standard.
- Le **FWD** (traction avant) se positionne au centre, reflétant sa présence transversale dans toutes les catégories de véhicules courants.

4.9 Conclusion de l'AFC

L'AFC a révélé deux structures d'association principales dans le catalogue de Forza Horizon 5 :

1. **Un clivage d'exclusivité temporelle** : certaines catégories iconiques (Cult Classics) sont réservées aux récompenses saisonnières limitées dans le temps, créant une dimension de rareté artificielle dans le jeu.
2. **Une logique de progression** : les véhicules atypiques (tracteurs, rally monsters) s'obtiennent en jouant et en progressant, pas en achetant — ils sont la récompense de l'implication du joueur.

5 Classification Hiérarchique Ascendante (CAH) — SAS

5.1 Pourquoi utiliser la CAH ?

L'ACP nous a montré que les véhicules se répartissent selon plusieurs dimensions (performance, gabarit, valeur). Mais elle ne crée pas directement des groupes : elle structure l'espace. La **Classification Hiérarchique Ascendante (CAH)** va plus loin en **partitionnant concrètement les véhicules en groupes homogènes**, appelés *clusters* ou *classes*.

L'objectif est de trouver des groupes de véhicules qui se ressemblent entre eux (homogènes à l'intérieur) et qui diffèrent des autres groupes (séparés à l'extérieur). Le résultat est une **segmentation exploitable**, par exemple pour comprendre comment le catalogue se structure naturellement ou pour comparer des groupes de véhicules.

5.2 Principe de la méthode de Ward

La CAH fonctionne de façon ascendante : au départ, chaque véhicule est son propre groupe. À chaque étape, les deux groupes les plus *proches* sont fusionnés. Le processus continue jusqu'à n'avoir plus qu'un seul grand groupe.

La **méthode de Ward** définit la proximité entre deux groupes par la perte d'information que provoque leur fusion. À chaque étape, on fusionne les deux groupes dont le regroupement **augmente le moins la variance interne** :

$$\Delta(G_A, G_B) = \frac{n_A \cdot n_B}{n_A + n_B} \cdot \|\bar{\mathbf{x}}_A - \bar{\mathbf{x}}_B\|^2$$

où $\bar{\mathbf{x}}_A$ et $\bar{\mathbf{x}}_B$ sont les centroïdes (moyennes) des deux groupes, et n_A, n_B leurs tailles.

La **qualité globale** d'une partition est mesurée par le R^2 :

$$R^2 = \frac{\text{Variance inter-classes}}{\text{Variance totale}}$$

Le R^2 semi-partiel (SPRSQ) mesure la perte d'information à chaque fusion : un grand saut dans le SPRSQ signale qu'on fusionne deux groupes très distincts. C'est ce signal qui permet de choisir le bon nombre de classes.

5.3 Préparation des données pour la CAH

La CAH sous SAS est appliquée sur les **10 mêmes variables quantitatives** que l'ACP. La **standardisation préalable** est indispensable : sans elle, des variables exprimées dans de grandes unités (le prix, qui peut valoir plusieurs millions de crédits) domineraient artificiellement le calcul des distances, au détriment des scores de performance (notés sur 10).

Les variables qualitatives ne participent pas à la création des classes mais servent ensuite à **nommer et caractériser** les clusters obtenus.

5.4 Résultat 1 — Choix du nombre de classes




Figure 14: Évolution du R^2_{global} selon le nombre de class

Lecture du graphique : L'analyse du graphique du coude (R^2 semi-partiel) montre une cassure nette à 2 classes, suivie d'une stabilisation de la perte d'information à partir de 3 classes. Une partition en 2 ou 3 classes offre donc le meilleur compromis. Retenir 3 classes permet de capturer l'essentiel de la structure des données (avec un SPRSQ faible d'environ 0,07), tandis qu'une 4ème classe complexifierait le modèle sans gain d'information significatif.

5.5 Résultat 2 — Le dendrogramme




Figure 15: dendrogramme

Lecture du graphique : Le dendrogramme simplifié représente visuellement la hiérarchie des dernières fusions de notre classification. Contrairement à un arbre classique, il se lit ici de gauche à droite : les branches partent des 3 clusters finaux identifiés à gauche (CL3, CL6 et CL4) et se regroupent vers la droite à mesure que le niveau de dissimilarité augmente.

On observe d'abord la fusion des nœuds CL3 et CL6 lorsque l'on passe à 2 classes (au niveau de l'axe horizontal 2.0), puis le regroupement final avec CL4 qui forme l'unique classe globale (au niveau 1.0). Ce graphique confirme de manière très claire et lisible la structure de notre partition en 3 classes.

5.6 Résultat 3 — Profil des 3 clusters




Figure 16: Profils des 3 classes selon les variables Speed, Horse Power et Offroad

Lecture du graphique : L'analyse des boîtes à moustaches permet de caractériser précisément les 3 classes retenues : Classe 1 : Les Supercars de haute performance. Ce groupe se distingue par les scores les plus élevés du catalogue en vitesse de pointe (speed médiane $\approx 7,5$) et en puissance moteur (Horse_Power médiane ≈ 550 ch). Les véhicules de cette classe affichent en contrepartie des capacités tout-terrain très limitées. Classe 2 : Les véhicules d'entrée/milieu de gamme polyvalents. Cette classe présente des performances modestes à intermédiaires, avec la puissance moteur la plus faible du jeu (médiane ≈ 250 ch) et un score de vitesse en retrait (médiane $\approx 5,6$). Le score Offroad y reste modéré. Classe 3 : Les spécialistes du Tout-Terrain (Offroad). Ce groupe se démarque de manière flagrante par ses aptitudes de franchissement, affichant un score Offroad exceptionnellement élevé (médiane > 8). En termes de motorisation, ces véhicules disposent d'une puissance intermédiaire à forte (médiane ≈ 400 ch) pour compenser leur gabarit, mais conservent une vitesse de pointe plus faible.

Le tableau suivant résume les 3 classes identifiées par la CAH :

Table 4: Synthèse des 3 classes de véhicules identifiées par la CAH

Cluster	Profil	Variables dominantes	Exemples de véhicules
1	Supercars hautes performances	Horse_Power très élevé, speed maximale, Offroad très faible, prix élevé	Bugatti Chiron, Ferrari LaFerrari, McLaren P1
2	Sportives et compactes accessibles	Performances modérées à intermédiaires, Horse_Power le plus faible, speed en retrait, prix modéré	Volkswagen Golf GTI, Renault Clio RS, Subaru BRZ
3	Monstres du Tout-Terrain	Offroad exceptionnellement élevé, Horse_Power élevé, vitesse moyenne	Jeep Wrangler, Ford Ranger Raptor, Mercedes-Benz G-Class

5.7 Conclusion de la CAH

La CAH a permis de structurer le catalogue de véhicules en 3 groupes concrets, distincts et parfaitement interprétables. Cette segmentation reflète des choix de game design clairs, opposant la vitesse pure sur asphalte aux capacités de franchissement hors-piste, tout en maintenant un groupe central de véhicules plus accessibles pour le joueur.

6 Analyse des Correspondances Multiples (ACM) — SAS

6.1 Pourquoi utiliser l'ACM ?

L'AFC a étudié l'association entre **deux** variables qualitatives (catégorie du véhicule $\times$ mode d'obtention). Mais le catalogue de Forza Horizon 5 possède plusieurs variables qualitatives importantes : la catégorie, la transmission, la décennie de fabrication, et des variables de performance discrétisées (puissance, vitesse, note, prix). Analyser toutes ces variables deux à deux nécessiterait de nombreux tableaux et serait difficile à synthétiser.

L'**Analyse des Correspondances Multiples (ACM)** résout ce problème en analysant **simultanément** plusieurs variables qualitatives. Elle produit un plan factoriel où chaque **modalité** (chaque valeur possible de chaque variable) est représentée par un point. Les modalités proches dans ce plan sont souvent présentes ensemble chez les mêmes véhicules.

Concrètement, l'ACM permet de répondre à la question : *quels profils multidimensionnels de véhicules peut-on identifier en combinant simultanément la catégorie, la transmission, la décennie, la puissance, la vitesse, la note et le prix ?*

6.2 Différence avec l'AFC

Critère	AFC	ACM
Nombre de variables	2	3 ou plus
Tableau d'entrée	Tableau de contingence (2 variables)	Tableau disjonctif complet (toutes les variables)
Résultat	Associations entre 2 variables	Profils multidimensionnels
Usage	Tester un lien précis	Explorer la structure globale

6.3 Principe de la méthode

L'ACM construit un **tableau disjonctif complet** $\mathbf{Z}$, de dimension $n \times K$ où K est le nombre total de modalités sur l'ensemble des variables. Chaque ligne (véhicule) contient des 0 et des 1 : exactement un 1 par variable, dans la colonne correspondant à la modalité du véhicule.

L'ACM est ensuite équivalente à une AFC appliquée à ce tableau :

$$\phi^2 = \frac{1}{q} \sum_{k=1}^q \frac{\chi_k^2}{n}$$

où q est le nombre de variables qualitatives. Les coordonnées factorielles sont obtenues par décomposition spectrale du **tableau de Burt** $\mathbf{B} = \mathbf{Z}^\top \mathbf{Z}$.

6.4 Préparation : discrétisation des variables

L'ACM ne fonctionne qu'avec des variables qualitatives. Certaines de nos variables utiles (puissance, vitesse, note, prix) sont numériques. Il faut donc les **discrétiser** : les transformer en catégories ordonnées.

Les seuils retenus sont basés sur les quartiles de la distribution et sur des ruptures métiers cohérentes :

Variable créée	Variable source	Modalités
HP_cat	Horse_Power	Faible (≤ 200 ch), Moyen (200-400ch), Fort (400-600ch), Extrême (> 600 ch)
speed_cat	speed	Lent (≤ 4), Moyen (4-6), Rapide (6-8), Très rapide (> 8)
rating_cat	Stock_Rating	Faible (≤ 500), Moyen (500-700), Bon (700-850), Excellent (> 850)
prix_cat	In_Game_Price	Accessible (≤ 100 k), Intermédiaire (100k-500k), Premium (500k-1M), Luxe (> 1 M)
decennie	Year	Avant 1960, Années 60, 70, 80, 90, 2000, 2010+
Drive_clean	Drive_Type	FWD, RWD, AWD
Model_clean	Model_type	38 catégories du jeu

Pourquoi discrétiser et pas simplement utiliser les valeurs numériques ? Parce que l'ACM fonctionne sur des associations entre modalités, pas sur des valeurs continues. La discrétisation permet également de révéler des **seuils de rupture** : par exemple, la frontière entre les véhicules “accessibles” (sous 100 000 crédits) et les “premiums” est une frontière économique importante dans le jeu.

6.5 Résultat 1 — Plan factoriel des modalités




Figure 17: Plan factoriel

Le plan factoriel de l'ACM représente chaque **modalité** comme un point. Les modalités proches sont souvent présentes ensemble chez les mêmes véhicules. Les oppositions entre modalités éloignées révèlent des clivages dans le catalogue.

Lecture du graphique : La classification des modalités de l'ACM fait émerger 3 profils distincts parfaitement sectorisés sur le plan factoriel :

Cluster 1 (Bleu — En bas) : Véhicules courants et compétitions modernes. Ce groupe central associe les décennies récentes (YR_6_Annees2000, 2010plus) aux catégories polyvalentes ou de rallye (OFFROAD, MODERN RALLY). Il se caractérise par des transmissions AWD ou FWD, des performances moyennes (HP_2_Moyen, SP_2_Rapide) et des prix accessibles.

Cluster 2 (Orange — En haut / Droite) : Modèles historiques et petits gabarits. Ce groupe isole la dimension temporelle en rassemblant les voitures de collection et les décennies anciennes (YR_1_Avant1960, VINTAGE RACERS, CULT CLASSICS). Le flanc droit y agrège logiquement les performances les plus faibles du catalogue (SP_1_Lente, HP_1_Faible).

Cluster 3 (Vert — À gauche) : L'élite des Supercars de haute performance. Concentré sur la gauche de l'Axe 1, ce cluster réunit les catégories reines du jeu (HYPERCARS, SUPER GT) associées aux caractéristiques maximales : puissance extrême (HP_4_Tres_Puissant), vitesse de pointe élevée (SP_3_Tres_Rapide) et

budgets de luxe (PR_4_Luxe).

Cette classification confirme la robustesse de l'étude : le Cluster 3 (Vert) valide le groupe des Supercars (Cluster 1 de la CAH), tandis que l'ACM apporte une réelle valeur ajoutée en isolant l'histoire et l'ancienneté des véhicules via le Cluster 2 (Orange).

6.6 Résultat 2 — Classification des modalités




Figure 18: Classification des modalités

Lecture du graphique : Le dendrogramme des modalités actives permet de visualiser la hiérarchie de regroupement des catégories du catalogue de véhicules selon la méthode de Ward. L'axe vertical représente la perte d'inertie exprimée en R^2 (allant de 1.00 en bas à 0.00 au sommet). Contrairement au graphique précédent, cet arbre se lit de bas en haut : les modalités qui fusionnent rapidement près de la base ($R^2 \geq 0.75$) partagent de fortes similitudes et caractérisent des profils de véhicules identiques dans le jeu.

En observant la structure globale de l'arbre, la première séparation majeure s'effectue tout en haut (au niveau $R^2 \approx 0.00$), scindant le catalogue en deux très grands blocs distincts : Le bloc de gauche : Il isole de manière très nette le groupe de la très haute performance, du luxe et de la vitesse pure (HYPERCARS, SUPER GT, PR_4_Luxe, SP_3_Tres_Rapide). Le bloc de droite : Il rassemble toutes les autres catégories du jeu (véhicules tout-terrain, voitures rétro, compactes grand public, etc.), qui se subdivisent ensuite en sous-branches plus spécifiques. Cette configuration confirme visuellement que la distinction entre "l'élite ultra-performante" et le reste du catalogue constitue le clivage fondamental et le plus structurant des données.

ce qui valide parfaitement les observations faites sur l'Axe 1 de l'ACM.

6.7 Résultat 3 — Cohérence avec l'ACP et la CAH

L'ACM confirme et enrichit les résultats des analyses précédentes. Les 3 profils identifiés sur le plan factoriel correspondent exactement aux grandes structures déjà détectées lors des étapes précédentes :

Le groupe des Supercars modernes : Il associe les modalités de performance situées à gauche de l'axe 1 de l'ACM (HYPERCARS, SP_3_Tres_Rapide) et correspond parfaitement au Cluster 1 de la CAH (les véhicules ultra-performants).

Le groupe des véhicules Tout-Terrain : Il regroupe les modalités liées au franchissement (OFFROAD, TRUCKS) et correspond directement au Cluster 3 de la CAH (les monstres du hors-piste).

Le groupe des véhicules courants et rétro : Il rassemble la masse des voitures quotidiennes, compactes ou plus anciennes (HOT HATCH, PR_1_Accessible) situées à droite de l'axe 1 de l'ACM, ce qui correspond au Cluster 2 de la CAH.

Cette convergence parfaite entre les trois approches (ACP, CAH et ACM) est un signal fort : les structures identifiées sont robustes et réelles. Elles ne dépendent pas d'un algorithme en particulier, mais traduisent une véritable logique d'équilibrage et de segmentation dans le catalogue de véhicules du jeu.

6.8 Conclusion de l'ACM

L'ACM a permis d'obtenir une vision **multidimensionnelle et simultanée** de la structure du catalogue. Elle apporte plusieurs éléments nouveaux par rapport aux analyses précédentes :

- Elle introduit la **dimension temporelle** (décennie de fabrication) comme un axe structurant à part entière, confirmant que l'âge d'un véhicule est un facteur aussi important que ses performances pour comprendre sa place dans le catalogue.
- Elle révèle que le prix et la transmission sont étroitement liés à la décennie de fabrication : les voitures chères et rares sont aussi les plus anciennes et les plus souvent à propulsion arrière.
- Elle confirme la **cohérence interne** des regroupements identifiés par toutes les méthodes précédentes.

7 Conclusion Générale

7.1 Synthèse des résultats

Ce projet d'analyse statistique multivariée a permis d'explorer de manière approfondie et complémentaire le catalogue automobile de *Forza Horizon 5*. L'application successive de quatre méthodes fondamentales (ACP, AFC, CAH, ACM) a fait émerger une structure logique et robuste, démontrant que les choix de modélisation des développeurs (*game design*) répondent à des critères statistiques bien réels.

Le tableau suivant résume l'apport de chaque méthode au sein de notre démarche :

Méthode	Logiciel	Ce qu'elle analyse	Principal résultat
ACP	R	10 variables quantitatives	Extraction de 3 axes majeurs (Performance, Gabarit/Offroad, Valeur financière).
AFC	R	2 variables qualitatives	Mise en évidence d'une logique d'obtention liée à la rareté temporelle (<i>Season Events</i>).
CAH	SAS	Segmentation des individus	Partition optimale en 3 clusters distincts (Supercars, Véhicules polyvalents, Tout-terrain).
ACM	SAS	7 variables qualitatives simultanées	Structuration conjointe de la performance et de la temporalité (Clivage Ancien/Moderne).

7.2 Réponse à la problématique

En croisant les résultats de ces différentes méthodes, nous pouvons affirmer que le catalogue de véhicules de *Forza Horizon 5* est rigoureusement structuré autour de **trois piliers indépendants** :

1. **La performance pure sur asphalte** : Il s'agit de la dimension la plus discriminante (55,5 % de la variance en ACP, validée par l'axe 1 de l'ACM). Elle oppose de façon radicale l'élite technologique (Hypercars et Supercars) aux citadines et compactes d'entrée de gamme. C'est le socle historique du jeu de course.
2. **L'aptitude au franchissement (Gabarit et Tout-terrain)** : Totalelement indépendante de la vitesse de pointe, cette dimension isole les véhicules lourds à forte motricité (Jeeps, Trucks, SUV). Elle répond à la diversité de la topographie du jeu (jungle, désert, volcans) qui exige un gameplay adapté hors-piste.
3. **La valeur historique et culturelle (Raréfaction)** : Mis en lumière par l'ACP (axe 3) et l'ACM (axe 2), l'âge d'un véhicule définit un statut économique indépendant des performances. Les pièces de collection les plus anciennes (souvent à propulsion arrière / RWD) affichent des prix records à l'Autoshow ou sont introduites comme des récompenses exclusives et temporaires (*Season Events*) pour fidéliser les joueurs.

7.3 Limites de l'étude et perspectives

Bien que les structures identifiées soient robustes et convergentes, ce travail présente quelques limites méthodologiques :

- **Nature artificielle des données :** S'agissant d'un jeu vidéo, les variables de performance ne mesurent pas des grandeurs physiques réelles, mais découlent d'algorithmes d'équilibrage conçus par Playground Games. Les résultats décrivent l'écosystème du jeu, non la réalité du marché automobile.
- **Subjectivité de la discrétisation :** Le découpage en classes pour les besoins de l'ACM (notamment sur la puissance ou les prix) comporte une part d'arbitraire. Une modification des seuils de quartiles pourrait légèrement déplacer certaines modalités sur le plan factoriel.
- **Seuil de significativité de l'AFC :** Le test du chi-deux de l'AFC affichant une p-value de 0,099 (supérieure au seuil alpha de 5 %), la lecture de la relation entre les catégories et les modes d'obtention doit conserver un caractère strictement exploratoire.
- **Biais d'imputation :** L'imputation par la médiane des valeurs manquantes sur la variable `Horse_Power` a créé une concentration artificielle au centre de la distribution, bien que ce choix reste statistiquement plus robuste qu'une suppression pure et simple des individus concernés.

En ouverture, il serait intéressant d'intégrer dans une étude future les données de télémétrie des joueurs (véhicules les plus fréquemment pilotés) afin de croiser la structure théorique du catalogue avec l'utilisation réelle faite par la communauté.

8 Annexes

8.1 Annexe A — Code R complet

```
# =====
# SAE 4-02 | BUT Science des Données --- IUT d'Avignon
# Analyses Multivariées : Forza Horizon 5 Cars
# Auteur : Ngaleu Trésor | 2025-2026
# =====

library(FactoMineR); library(factoextra); library(RColorBrewer)
library(stringr); library(dplyr); library(ggplot2)
library(corrplot); library(tidyr); library(scales)

# --- 1. Importation ---
car <- read.csv("Forza_Horizon_Cars.csv", sep=",", header=TRUE)

# --- 2. Nettoyage ---
car_clean <- car
car_clean[car_clean == "info_not_found"] <- NA
car_clean <- car_clean %>%
  mutate(
    In_Game_Price = as.numeric(str_replace_all(In_Game_Price, ",", "")),
    Weight_lbs     = as.numeric(str_replace_all(Weight_lbs,   ",", "")),
    Top_Speed      = as.numeric(str_remove(Top_Speed,   " Mph")),
    X0.60_Mph      = as.numeric(str_remove(X0.60_Mph,    "s")),
    X0.100_Mph     = as.numeric(str_remove(X0.100_Mph,   "s")),
    g.force        = as.numeric(str_remove(g.force,     " g"))
  ) %>%
  mutate(across(c(speed, handling, acceleration, launch, braking,
                  Offroad, Stock_Rating, Horse_Power), as.numeric))

car_clean_2 <- car_clean %>%
  dplyr::select(-car_source_2, -X0.100_Mph, -Top_Speed,
               -X0.60_Mph, -g.force) %>%
  mutate(Year = as.character(str_extract(Name_and_model, "\\d{4}")),
         Model = str_remove(Name_and_model, "\\d{4}\\s+")) %>%
  dplyr::select(-Name_and_model, -car_source_1) %>%
  filter(!is.na(Model_type), !is.na(Drive_Type)) %>%
  mutate(across(c("Horse_Power", "Stock_Rating", "speed", "handling",
                  "acceleration", "launch", "braking", "Offroad",
                  "In_Game_Price", "Weight_lbs"),
               ~ ifelse(is.na(.), median(., na.rm=TRUE), .)))

# --- 3. ACP ---
data_quant <- car_clean_2 %>% select_if(is.numeric) %>%
```

```

  mutate(across(everything(), ~ ifelse(is.na(.), median(., na.rm=TRUE), .)))
rownames(data_quant) <- make.unique(car_clean_2$Model)
res.pca <- PCA(data_quant, scale.unit=TRUE, graph=FALSE)

# Scree plot
fviz_screplot(res.pca, addlabels=TRUE) +
  geom_hline(yintercept=1, linetype="dashed", color="red")

# Cercle des corrélations
plot(res.pca, choix="var")
plot(res.pca, axes=c(1,3), choix="var")

# Contributions
fviz_contrib(res.pca, choice="var", axes=1)
fviz_contrib(res.pca, choice="var", axes=2)

# Individus
fviz_pca_ind(res.pca, col.ind="cos2",
             gradient.cols=c("#BBDEFB", "#OD47A1"),
             select.ind=list(cos2=20), repel=TRUE)

# Biplot
fviz_pca_biplot(res.pca, repel=TRUE, col.var="#E53935",
                select.ind=list(cos2=20))

# --- 4. AFC ---
car_afc <- car_clean_2 %>% filter(!is.na(Model_type) & !is.na(car_source))
tab_contingence <- table(car_afc$Model_type, car_afc$car_source)
rownames(tab_contingence) <- abbreviate(rownames(tab_contingence),
                                       minlength=5, use.classes=TRUE)

chisq.test(tab_contingence)

res2.ca <- CA(tab_contingence, graph=FALSE)
fviz_eig(res2.ca)
fviz_ca_biplot(res2.ca,
               select.row=list(cos2=0.7), select.col=list(cos2=0.7),
               geom.row=c("point", "text"), geom.col=c("point", "text"),
               repel=TRUE, col.row="royalblue", col.col="#DC143C")

# AFC + variable supplémentaire
tab_sup <- rbind(tab_contingence,
                 table(car_afc$Drive_Type, car_afc$car_source))
res.ca_sup <- CA(tab_sup,
                 row.sup=(nrow(tab_contingence)+1):nrow(tab_sup),
                 graph=FALSE)
fviz_ca_biplot(res.ca_sup, col.row.sup="#FF8F00", repel=TRUE)

```

8.2 Annexe B — Code SAS complet

```
/* =====  
SAE 4-02 | BUT Science des Données --- IUT d'Avignon  
Auteur : Ngaleu Trésor | 2025-2026  
===== */  
  
/* ---- 1. Importation ---- */  
proc import  
    datafile="/home/u64327617/sas_reporting_multivaree_sas/Forza_Horizon_Cars.csv"  
    out=car dbms=csv replace;  
    guessingrows=max; getnames=yes;  
run;  
  
/* ---- 2. Nettoyage ---- */  
data car_clean;  
    set car;  
    array chars{*} _character_;  
    do i=1 to dim(chars);  
        if chars{i}="info_not_found" then chars{i}=""; end;  
    drop i;  
run;  
  
data car_clean2;  
    set car_clean;  
    drop car_source_2 X0_100_Mph X0_60_Mph Top_Speed g_force;  
    if missing(Model_type) then delete;  
    if missing(Drive_Type) then delete;  
    Year = input(substr(Name_and_model,1,4),4.);  
    Model = substr(Name_and_model,6);  
    drop Name_and_model;  
run;  
  
proc stdize data=car_clean2 out=car_clean3 method=median reponly;  
    var Horse_Power Stock_Rating speed handling acceleration  
        launch braking Offroad In_Game_Price Weight_lbs;  
run;  
  
/* ---- 3. CAH ---- */  
proc stdize data=car_clean3 out=car_std method=std;  
    var Horse_Power Stock_Rating speed handling acceleration  
        launch braking Offroad In_Game_Price Weight_lbs;  
run;
```

```
proc cluster data=car_std method=ward outtree=tree
    pseudo ccc rsquare;
    var Horse_Power Stock_Rating speed handling acceleration
        launch braking Offroad In_Game_Price Weight_lbs;
    id Model;
run;

ods graphics on / imagefmt=png width=1500px height=900px;
proc tree data=tree; id Model; height _rsq_; run;
ods graphics off;

/* Graphique du coude */
proc sort data=tree; by _ncl_; run;
data coude;
    set tree; by _ncl_;
    if first._ncl_;
    keep _ncl_ _sprsq_ _rsq_;
run;
proc sgplot data=coude;
    where _ncl_>0 and _ncl_<=20;
    series x=_ncl_ y=_sprsq_ / markers;
    xaxis reverse label="Nombre de classes";
    yaxis label="R2 semi-partiel (SPRSQ)";
    title "Graphique du coude";
run;

proc tree data=tree nclusters=3 out=classes; id Model; run;
proc means data=classes n mean std; class cluster;
    var Horse_Power Stock_Rating speed handling acceleration
        launch braking Offroad In_Game_Price Weight_lbs;
run;

/* ---- 4. ACM ---- */
data cars_acm;
    set car_clean3;
    if Horse_Power<=200 then HP_cat="HP_1_Faible";
    else if Horse_Power<=400 then HP_cat="HP_2_Moyen";
    else if Horse_Power<=600 then HP_cat="HP_3_Fort";
    else
        HP_cat="HP_4_Extreme";

    if speed<=4 then speed_cat="SP_1_Lent";
    else if speed<=6 then speed_cat="SP_2_Moyen";
    else if speed<=8 then speed_cat="SP_3_Rapide";
    else
        speed_cat="SP_4_TresRapide";

    if Stock_Rating<=500 then rating_cat="RT_1_Faible";
```

```
else if Stock_Rating<=700 then rating_cat="RT_2_Moyen";
else if Stock_Rating<=850 then rating_cat="RT_3_Bon";
else
    rating_cat="RT_4_Excellent";

if      In_Game_Price<=100000 then prix_cat="PR_1_Accessible";
else if In_Game_Price<=500000 then prix_cat="PR_2_Intermediaire";
else if In_Game_Price<=1000000 then prix_cat="PR_3_Premium";
else
    prix_cat="PR_4_Luxe";

if      missing(Year) then decennie="YR_0_Manquant";
else if Year<1960      then decennie="YR_1_Avant1960";
else if Year<1970      then decennie="YR_2_Annees60";
else if Year<1980      then decennie="YR_3_Annees70";
else if Year<1990      then decennie="YR_4_Annees80";
else if Year<2000      then decennie="YR_5_Annees90";
else if Year<2010      then decennie="YR_6_Annees2000";
else
    decennie="YR_7_2010plus";

Drive_clean=strip(Drive_Type);
Model_clean=strip(Model_type);
keep HP_cat speed_cat rating_cat prix_cat decennie
    Drive_clean Model_clean;
run;

proc corresp data=cars_acm mca dims=2 outc=coord short;
    tables HP_cat speed_cat rating_cat prix_cat decennie
        Drive_clean Model_clean;
    title "ACM Forza Horizon 5";
run;

data coord_var; set coord; where _type_='VAR'; run;

proc sgplot data=coord_var;
    scatter x=dim1 y=dim2 / datalabel=_name_
        markerattrs=(size=8 color=steelblue);
    xaxis label="Axe 1 ACM"; yaxis label="Axe 2 ACM";
    title "Plan factoriel ACM --- Modalites";
run;

proc cluster data=coord_var method=ward outtree=tree_acm
    pseudo ccc rsquare;
    id _name_; var dim1 dim2;
run;

proc tree data=tree_acm nclusters=3 out=classes_acm; id _name_; run;
```

```

proc sort data=coord_var;  by _name_; run;
proc sort data=classes_acm; by _name_; run;
data plot_acm;
    merge coord_var(in=a) classes_acm(in=b);
    by _name_; if a and b;
run;

proc sgplot data=plot_acm;
    scatter x=dim1 y=dim2 / group=cluster
            datalabel=_name_
            markerattrs=(size=9);
    xaxis label="Axe 1 ACM"; yaxis label="Axe 2 ACM";
    title "Plan ACM colore par cluster de modalites";
run;

```

8.3 Annexe C — Tableau récapitulatif des méthodes

	ACP	AFC	CAH	ACM
Logiciel	R	R	SAS	SAS
Type de variables	Quantitatives	2 qualitatives	Quantitatives	3+ qualitatives
Axes / groupes	3 axes	2 axes	3 clusters	2 axes + 3 clusters
Variance / inertie	80,2 %	48,5 %	Perte SPRSQ $\approx 0,07$	~ 28 %
Profil dominant	Performance Gabarit	/ Exclusivité / Pro- gression	3 segments métiers	3 profils types

Table 8: Tableau récapitulatif des méthodes et résultats

Rapport réalisé avec R Markdown et compilé en PDF via pdflatex. Données : Forza Horizon 5 Cars Dataset — Kaggle (deepcontractor, CC0). Université d'Avignon — IUT — BUT Science des Données — 2025–2026.