

IUT d'Avignon

Département Science des Données

BUT Science des Données — 2^{ème} Année

Régression Linéaire Multiple

Prédiction du Prix des Voitures

sur le Marché Américain — Cas Geely Auto

Projet Académique

Situation d'Apprentissage et d'Évaluation (SAE)

Participants : Ngaleu Tresor
Ycham Athoumani

Établissement : IUT d'Avignon

Date : April 10, 2026

Ce rapport présente une démarche complète de modélisation statistique appliquée à la prédiction des prix automobiles sur le marché américain.

Régression Linéaire Multiple – Prédiction du Prix des Voitures

SAE : Modélisation Statistique et Sélection de Modèles

10 avril 2026

Contents

1	Introduction Générale	2
1.1	Contexte du Projet	2
1.2	Problématique	2
1.3	Objectifs de l'Étude	2
2	Description du Jeu de Données	3
2.1	Origine et Source des Données	3
2.2	Structure du Jeu de Données	3
2.3	Dictionnaire des Variables	3
2.4	Statistiques Descriptives Rapides	3
2.5	Chargement des Données et Vérifications Préliminaires	4
3	Analyse Exploratoire des Données	5
3.1	Distribution de la Variable Cible : le Prix	5
3.2	Relation entre les Variables Quantitatives et le Prix	5
3.3	Impact du Mode de Propulsion sur le Prix	6
4	La Régression Linéaire Multiple	7
4.1	Principe et Formule Mathématique	7
4.2	Préparation des Données Quantitatives	7
4.3	Matrice de Dispersion	8
4.4	Estimation du Modèle Complet	8
4.5	Analyse des Résidus du Modèle Initial	9
4.6	Nettoyage des Observations Influentes	11
4.6.1	Procédure Itérative de Nettoyage (Seuil 3,5 écarts-types)	12
4.7	Modèle Nettoyé – Évaluation de la Qualité	12
4.8	Graphique : Valeurs Observées vs Prédites	14
4.9	Test de Normalité des Résidus (Shapiro-Wilk)	15
4.10	Vérification de l'Homoscédasticité	16
4.11	Intervalles de Confiance des Estimateurs MCO	16
4.12	Variables Significatives au Seuil de 5 %	17
4.13	Prévisions sur 10 Nouvelles Observations	17
5	L'Analyse de la Variance (ANOVA)	19
5.1	Principe et Formulation Mathématique	19
5.2	Préparation et Quantités de l'ANOVA	19
5.3	Analyse Graphique Exploratoire	20
5.4	Lancement de l'ANOVA et Diagnostics	20
5.5	Nettoyage et ANOVA Finale	21
5.6	Comparaisons Multiples (Tests Post-Hoc)	22
5.6.1	Test de Tukey (HSD)	22
5.6.2	Test de Scheffé (Confirmation)	23

6	Sélection de Facteurs (Optimisation du Modèle)	24
6.1	Recherche de Colinéarité (VIF)	24
6.2	Sélection Pas-à-Pas (Stepwise – Critère AIC)	25
6.3	Recherche Exhaustive (regsubsets)	27
6.4	Modèle de Prévion – Critère BIC (6 Variables)	28
6.4.1	Analyse des Résidus du Modèle_prédiction	29
6.5	Modèle de Modélisation – Critère C_p de Mallows (8 Variables)	30
6.5.1	Analyse des Résidus du Modèle_modélisation	31
6.6	Vérification Finale de la Colinéarité	32
6.7	Validation et Comparaison Finale des Modèles sur des nouvelles observations	33
7	Conclusion Générale	35
7.1	Synthèse des Résultats	35
7.2	Recommandations pour Geely Auto	35
7.3	Limites du Modèle	35

Contents

1 Introduction Générale

1.1 Contexte du Projet

Dans le cadre de cette SAE (*Situation d'Apprentissage et d'Évaluation*) de deuxième année de BUT Science des Données, ce projet propose une mise en pratique des outils de la statistique décisionnelle. À l'aide du logiciel R, nous mettons en œuvre des méthodologies de modélisation linéaire – régression multiple, ANOVA et sélection de modèles – pour répondre à un besoin concret d'analyse de données réelles.

L'enjeu est de passer d'une simple analyse exploratoire à une démarche de modélisation rigoureuse, permettant non seulement de comprendre les mécanismes de formation d'une variable, mais aussi de réaliser des prévisions fiables.

Le projet s'inscrit dans une démarche de conseil stratégique pour le constructeur automobile chinois **Geely Auto**. Souhaitant s'implanter sur le marché américain pour concurrencer les constructeurs locaux et européens, Geely Auto fait face à un défi majeur : le marché américain est fondamentalement différent du marché chinois. Pour réussir cette insertion, l'entreprise a mandaté une société de conseil pour analyser les prix pratiqués aux États-Unis.

1.2 Problématique

La question centrale de cette étude est la suivante :

Quels sont les facteurs déterminants qui régissent le prix de vente d'un véhicule sur le marché américain, et comment pouvons-nous modéliser mathématiquement ces relations pour prédire avec précision le positionnement tarifaire d'un nouveau modèle Geely Auto ?

Pour y répondre, nous devons identifier si les variables techniques (puissance, taille du moteur) ont plus de poids que les variables de confort ou de design, tout en veillant au respect des conditions de validité statistique (normalité, homoscedasticité, absence de colinéarité).

1.3 Objectifs de l'Étude

Afin de répondre à la problématique de Geely Auto, nos travaux se divisent en plusieurs objectifs opérationnels :

1. **Préparation et Nettoyage des Données** : identifier et traiter les valeurs aberrantes (*outliers*) et les points influents qui pourraient biaiser les estimations.
2. **Modélisation par Régression Multiple** : estimer l'impact de chaque variable quantitative sur le prix (*price*) et évaluer la précision des coefficients via les intervalles de confiance.
3. **Analyse de la Variance (ANOVA)** : étudier l'influence des variables qualitatives (type de propulsion, nombre de portes) sur le prix moyen des véhicules.
4. **Optimisation du Modèle** : appliquer des procédures de sélection de facteurs (Stepwise, critères BIC, AIC, C_p de Mallows) pour obtenir le modèle le plus **parcimonieux**.
5. **Validation et Prévision** : tester la capacité prédictive du modèle final sur de nouvelles données et quantifier l'erreur de prévision via le MSE (*Mean Squared Error*).

2 Description du Jeu de Données

2.1 Origine et Source des Données

Ce jeu de données a été conçu pour analyser les facteurs influençant le prix des automobiles sur le marché américain. Il est particulièrement adapté aux exercices de régression et d'analyse de données.

- **Source** : *Car Price Prediction* (Kaggle)
- **Auteur original** : Arash Nic (Data Scientist)
- **Publication** : Utilisateur Hellbuoy sur Kaggle
- **Contexte** : Aider l'entreprise Geely Auto à identifier les variables influençant les prix pour entrer sur le marché américain

2.2 Structure du Jeu de Données

Le jeu de données se compose de **205 entrées** (lignes) et **26 colonnes** (variables). Il ne contient **aucune valeur manquante**, ce qui en fait un jeu de données propre et directement exploitable pour l'analyse.

- **Nombre d'observations** : 205 véhicules
- **Nombre de variables** : 26 (25 variables explicatives + 1 variable cible)
- **Variable cible** : *price* (le prix de vente de la voiture en dollars)
- **Valeurs manquantes** : aucune (0)
- **Doublons** : aucun (0)

2.3 Dictionnaire des Variables

Le jeu contient un mélange de variables numériques et catégorielles, organisées en plusieurs catégories :

Catégorie	Variables	Description
Identification	<i>car_ID</i> , <i>CarName</i>	Identifiant unique et nom de la voiture
Caractéristiques physiques	<i>wheelbase</i> , <i>carlength</i> , <i>carwidth</i> , <i>carheight</i> , <i>curbweight</i>	Dimensions et poids à vide
Moteur & Performance	<i>enginesize</i> , <i>horsepower</i> , <i>peakrpm</i> , <i>enginetype</i> , <i>cylindernumber</i>	Puissance, cylindrée, régime moteur
Consommation	<i>citympg</i> , <i>highwaympg</i>	Consommation en ville et sur autoroute
Spécifications techniques	<i>fueltype</i> , <i>aspiration</i> , <i>drivewheel</i> , <i>enginelocation</i>	Carburant, aspiration, type de transmission
Design	<i>carbody</i> , <i>doornumber</i>	Carrosserie et nombre de portes
Risque	<i>symboling</i>	Score d'assurance (-2 à +3)
Variable cible	<i>price</i>	Prix de vente (\$)

2.4 Statistiques Descriptives Rapides

Avant toute modélisation, voici les grandes tendances du marché étudié :

- **Prix moyen** : environ 13 276 \$
- **Intervalle de prix** : de 5 118 \$ à 45 400 \$
- **Puissance moyenne** : 104 chevaux
- **Marques les plus fréquentes** : Toyota (la plus représentée), Nissan, Mazda, Honda, ainsi que des marques de luxe comme BMW, Jaguar ou Porsche

2.5 Chargement des Données et Vérifications Préliminaires

```
# Lecture du jeu de donnees
df <- read.csv("CarPrice_Assignment.csv", header = TRUE, sep = ",")

# Verifications de base
cat("Dimensions :", nrow(df), "lignes x", ncol(df), "colonnes\n")

## Dimensions : 205 lignes x 26 colonnes
cat("Valeurs manquantes :", sum(is.na(df)), "\n")

## Valeurs manquantes : 0
cat("Doublons :", sum(duplicated(df)), "\n")

## Doublons : 0
# Apercu de la structure
str(df[, c("price", "enginesize", "horsepower", "fueltype", "carbody",
           "drivewheel", "doornumber")])

## 'data.frame':    205 obs. of  7 variables:
## $ price      : num  13495 16500 16500 13950 17450 ...
## $ enginesize: int   130 130 152 109 136 136 136 136 131 131 ...
## $ horsepower: int   111 111 154 102 115 110 110 110 140 160 ...
## $ fueltype   : chr   "gas" "gas" "gas" "gas" ...
## $ carbody    : chr   "convertible" "convertible" "hatchback" "sedan" ...
## $ drivewheel: chr   "rwd" "rwd" "rwd" "fwd" ...
## $ doornumber: chr   "two" "two" "two" "four" ...
```

Le jeu de données est **propre** : aucune valeur manquante, aucun doublon. Nous disposons de 205 observations et 26 variables.


```
# Statistiques descriptives de la variable cible
summary(df$price)

##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      5118   7788   10295   13277   16503   45400
cat("\nEcart-type du prix :", round(sd(df$price), 0), "$\n")

##
## Ecart-type du prix : 7989 $
```


3 Analyse Exploratoire des Données

3.1 Distribution de la Variable Cible : le Prix



Interprétation : La distribution est **asymétrique vers la droite** cela signifie la grande majorité des véhicules se situent entre 5 000 \$ et 15 000 \$, avec une médiane autour de 10 000 \$, tandis qu'un petit nombre de modèles de luxe dépasse les 30 000 \$. Le boxplot confirme la présence de **valeurs atypiques** (astérisques rouges) correspondant à des véhicules haut de gamme (BMW, Jaguar, Porsche). Ces points devront être surveillés lors de la modélisation pour éviter qu'ils ne biaisent les estimations.

3.2 Relation entre les Variables Quantitatives et le Prix



Interprétation : Les deux nuages de points montrent une relation **linéaire positive** claire. La droite rouge (régression simple) traverse bien le nuage et confirme ce lien. La zone grise (intervalle de confiance) est très étroite pour les puissances inférieures à 150 chevaux, indiquant une estimation très fiable pour la majorité des véhicules. Ces deux variables seront des candidates importantes dans le modèle multiple.

3.3 Impact du Mode de Propulsion sur le Prix




Figure 3: Comparaison des prix par type de propulsion (boxplot + jitter)

Interprétation : Le graphique révèle une séparation nette du marché en trois catégories. La traction (**fwd**) représente l'entrée de gamme avec des prix bas et très regroupés (< 10 000 \$). À l'inverse, la propulsion (**rwd**) incarne le segment haut de gamme : les prix y sont bien plus élevés (médiane à 17 000 \$) et beaucoup plus variés. Le (**4wd**) occupe une position intermédiaire. Cette différence visuelle flagrante justifie l'utilisation de l'ANOVA pour confirmer statistiquement que le type de transmission est un facteur déterminant du prix.

4 La Régression Linéaire Multiple

4.1 Principe et Formule Mathématique

Pour modéliser le prix en fonction de plusieurs caractéristiques simultanément, nous utilisons la **régression linéaire multiple**. Ce modèle suppose que le prix Y est une combinaison linéaire de p variables explicatives $X_1, X_2, \dots, X_p$:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \varepsilon$$

où :

- β_0 est l'**intercept** (valeur théorique du prix si toutes les variables sont nulles),
- β_j est le **coefficient** de la variable X_j (variation du prix quand X_j augmente d'une unité, toutes choses égales par ailleurs),
- $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ est le **terme d'erreur** (partie non expliquée par le modèle).

Les coefficients sont estimés par la méthode des **Moindres Carrés Ordinaires (MCO)**, qui minimise la somme des carrés des écarts :

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

4.2 Préparation des Données Quantitatives

```
# Selection des variables quantitatives uniquement
df_quant <- df[, sapply(df, is.numeric)]
df_quant$car_ID <- NULL # On retire l'identifiant, non informatif

cat("Nombre de variables quantitatives retenues :", ncol(df_quant) - 1, "\n")

## Nombre de variables quantitatives retenues : 14
cat("Variables :", paste(names(df_quant)[names(df_quant) != "price"], collapse = ", "), "\n")

## Variables : symboling, wheelbase, carlength, carwidth, carheight, curbweight, enginesize, boreratio,
```

4.3 Matrice de Dispersion




Figure 4: Matrice des nuages de points entre les variables quantitatives

Interprétation : La matrice révèle que de nombreuses relations avec le prix (dernière ligne) présentent une forme linéaire, ce qui **valide le choix de la régression linéaire**. On remarque aussi que certaines variables se ressemblent beaucoup (le poids et la taille du moteur, par exemple). Ce phénomène, appelé **multicolinéarité**, sera traité en Partie III.

4.4 Estimation du Modèle Complet

```
reg <- lm(price ~ ., data = df_quant)
summary(reg)
```

```
##
```

```
## Call:
## lm(formula = price ~ ., data = df_quant)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -10220.7  -1636.8   -118.2   1500.0  14454.4
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -5.165e+04  1.566e+04  -3.299  0.001160 **
## symboling      2.859e+02  2.433e+02   1.175  0.241523
## wheelbase     1.677e+02  1.075e+02   1.561  0.120256
## carlength    -9.482e+01  5.550e+01  -1.708  0.089200 .
## carwidth      4.666e+02  2.480e+02   1.882  0.061425 .
## carheight     1.948e+02  1.382e+02   1.409  0.160480
## curbweight     1.878e+00  1.736e+00   1.082  0.280718
## enginesize     1.168e+02  1.383e+01   8.443  7.82e-15 ***
## boreratio    -9.844e+02  1.195e+03  -0.824  0.410979
## stroke       -3.056e+03  7.780e+02  -3.928  0.000120 ***
## compressionratio 2.865e+02  8.342e+01   3.434  0.000730 ***
## horsepower    3.250e+01  1.626e+01   1.998  0.047105 *
## peakrpm       2.358e+00  6.703e-01   3.518  0.000544 ***
## citympg      -2.869e+02  1.799e+02  -1.595  0.112288
## highwaympg     1.913e+02  1.599e+02   1.196  0.233040
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 3186 on 190 degrees of freedom
## Multiple R-squared:  0.8519, Adjusted R-squared:  0.841
## F-statistic: 78.05 on 14 and 190 DF,  p-value: < 2.2e-16
```

Interprétation :

- Estimateurs des Moindres Carrés :** La colonne **Estimate** contient les coefficients $\hat{\beta}_j$. Par exemple, **enginesize** a un coefficient d'environ +117 : chaque unité supplémentaire de cylindrée augmente le prix de 117 \$.
- Précision des estimateurs :** La colonne **Std. Error** mesure l'incertitude. **boreratio** par exemple a une erreur type élevée, signalant une estimation incertaine.
- Le R^2 :** $R^2 = 0,852$ signifie que le modèle explique **85,2 %** de la variation du prix, ce qui est excellent.
- Variance des erreurs :** L'erreur standard des résidus (**Residual standard error**) vaut $\hat{\sigma} = 3186$ \$. La variance estimée est $\hat{\sigma}^2 = 3186^2 \approx 10\,150\,596$.
- Test simultané (F-test) :** La statistique $F = 78,05$ avec une p-value $< 2,2 \times 10^{-16}$ permet de rejeter H_0 : " tous les coefficients sont nuls ". Le modèle global est **statistiquement très significatif**.

4.5 Analyse des Résidus du Modèle Initial

Les hypothèses de validité du modèle linéaire sont vérifiées à partir de quatre graphiques : Residuals vs Fitted (linéarité), Normal Q-Q (normalité des résidus), Cook's Distance (influence des observations) et Residuals vs Leverage (levier).




Figure 5: Graphiques de diagnostic du modèle complet (avant nettoyage)

Interprétation :

1. Residuals vs Fitted (Linéarité) : Le graphique des résidus montre une légère courbe, ce qui indique que la relation entre les caractéristiques de la voiture et son prix n'est pas parfaitement droite. Dans un modèle idéal, les points devraient former un nuage totalement aléatoire autour de la ligne centrale mais dans ici elle n'est pas trop aléatoire (l'homoscédasticité pas trop Ok). Toutefois, cette déviation reste modérée et n'affecte pas significativement l'interprétation globale des coefficients. Pour cette raison, aucune transformation de la variable réponse n'a été appliquée, afin de conserver la lisibilité et l'interprétabilité du modèle.

2. Normal Q-Q (Normalité) : Les points s'écartent de la droite aux extrémités (observations 50, 129, 17), révélant des valeurs extrêmes difficiles à prédire. Les erreurs ne suivent pas une loi normale parfaite, révélant la présence de valeurs extrêmes que le modèle peine à prédire.

3. Cook's Distance (Influence) : L'observation 50 présente un pic très marqué. Cette voiture est très différente des autres et exerce une influence disproportionnée sur les résultats du modèle. La distance de Cook mesure l'influence de chaque observation :

$$D_i = \frac{\sum_{j=1}^n (\hat{y}_j - \hat{y}_{j(i)})^2}{p \cdot \hat{\sigma}^2}$$

Une valeur élevée signifie que cette observation "tire" la droite de régression de façon disproportionnée.

4. Residuals vs Leverage : Le point 50 est très isolé avec un fort levier, confirmant son statut de donnée atypique.

4.6 Nettoyage des Observations Influentes

L'analyse des graphiques de diagnostic met en évidence la présence d'observations influentes, notamment le point 50, caractérisé par une distance de Cook élevée et un résidu important traduisant une influence significative sur l'estimation des coefficients du modèle. De plus, le graphique des résidus en fonction des valeurs ajustées présente une structure non aléatoire, suggérant que certaines observations perturbent l'ajustement du modèle. Afin d'améliorer la stabilité des coefficients et la qualité globale du modèle, le point 50 va être supprimé. Cette suppression est justifiée par son influence disproportionnée sur la régression, tout en restant limitée afin de préserver la représentativité des données.

```
n_init <- nrow(df_quant)
df_quant2 <- df_quant[-c(50), ]
rownames(df_quant2) <- seq(1, n_init - 1)
reg2 <- lm(price ~ ., data = df_quant2)
summary(reg2)
```

```
##
## Call:
## lm(formula = price ~ ., data = df_quant2)
##
## Residuals:
```

	Min	1Q	Median	3Q	Max
##	-9574.7	-1477.8	-171.7	1616.2	13532.8

```
##
## Coefficients:
```

	Estimate	Std. Error	t value	Pr(> t)	
## (Intercept)	-4.158e+04	1.532e+04	-2.714	0.007273	**
## symboling	1.228e+02	2.384e+02	0.515	0.607135	
## wheelbase	1.401e+02	1.039e+02	1.348	0.179138	
## carlength	-8.047e+01	5.366e+01	-1.500	0.135397	
## carwidth	4.625e+02	2.392e+02	1.933	0.054692	.
## carheight	9.532e+01	1.357e+02	0.702	0.483418	
## curbweight	1.399e+00	1.679e+00	0.834	0.405551	
## enginesize	1.314e+02	1.386e+01	9.482	< 2e-16	***
## boreratio	-1.797e+03	1.171e+03	-1.535	0.126520	
## stroke	-3.851e+03	7.777e+02	-4.952	1.62e-06	***
## compressionratio	3.276e+02	8.116e+01	4.037	7.87e-05	***
## horsepower	3.439e+01	1.570e+01	2.191	0.029655	*
## peakrpm	2.405e+00	6.467e-01	3.719	0.000263	***
## citympg	-2.742e+02	1.735e+02	-1.580	0.115705	
## highwaympg	1.739e+02	1.543e+02	1.127	0.261293	

```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 3073 on 189 degrees of freedom
## Multiple R-squared:  0.8572, Adjusted R-squared:  0.8466
## F-statistic: 81.05 on 14 and 189 DF,  p-value: < 2.2e-16
```

Interprétation : Le retrait de l'observation 50 améliore le modèle (R^2 ajusté passe de 0,841 à 0.846). Cependant, les graphiques de diagnostic montrent que d'autres points restent problématiques (point 129). Nous allons appliquer une procédure itérative.

4.6.1 Procédure Itérative de Nettoyage (Seuil 3,5 écarts-types)

Cette procédure supprime une par une les observations dont le **résidu standardisé** dépasse le seuil de 3,5 :

$$r_i^* = \frac{e_i}{\hat{\sigma}\sqrt{1 - h_{ii}}}$$

Ce seuil est justifié par la loi normale : seulement 0,02 % des observations devraient naturellement dépasser $\pm 3,5$ écarts-types.

```
# Verification initiale de la proportion d'aberrants
reg3 <- lm(price ~ ., data = df_quant2)
res_std3 <- rstandard(reg3)
prop <- length(which(abs(res_std3) > 2)) / nrow(df_quant2) * 100
cat("Proportion d'aberrants avant boucle (|r| > 2) :", round(prop, 2), "%\n")
```

```
## Proportion d'aberrants avant boucle (|r| > 2) : 5.88 %
```

```
# Boucle de nettoyage iterative
repeat {
  reg_boucle <- lm(price ~ ., data = df_quant2)
  res_std <- rstandard(reg_boucle)
  idx_pire <- which.max(abs(res_std))
  if (abs(res_std[idx_pire]) <= 3.5) break
  df_quant2 <- df_quant2[-idx_pire, ]
  rownames(df_quant2) <- 1:nrow(df_quant2)
}

cat("Observations supprimees au total :", n_init - nrow(df_quant2), "%\n")
```

```
## Observations supprimees au total : 2
```

```
cat("Taille finale de l'echantillon :", nrow(df_quant2), "%\n")
```

```
## Taille finale de l'echantillon : 203
```

4.7 Modèle Nettoyé – Évaluation de la Qualité

```
reg_clean <- lm(price ~ ., data = df_quant2)
summary(reg_clean)

##
## Call:
## lm(formula = price ~ ., data = df_quant2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -9140.7 -1598.3  -237.9  1668.4  9323.7
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -4.415e+04  1.451e+04  -3.042  0.002686 **
## symboling    1.995e+02  2.262e+02   0.882  0.378936
## wheelbase    1.633e+02  9.845e+01   1.658  0.098893 .
## carlength   -1.069e+02  5.109e+01  -2.093  0.037686 *
## carwidth     5.456e+02  2.271e+02   2.403  0.017246 *
## carheight    1.208e+02  1.286e+02   0.939  0.348840
```

```
## curbweight      1.333e+00  1.589e+00  0.839 0.402432
## enginesize     1.264e+02  1.316e+01  9.608 < 2e-16 ***
## boreratio      -1.702e+03  1.109e+03 -1.536 0.126310
## stroke         -3.817e+03  7.361e+02 -5.185 5.56e-07 ***
## compressionratio 3.302e+02  7.682e+01  4.298 2.76e-05 ***
## horsepower     3.308e+01  1.486e+01  2.227 0.027160 *
## peakrpm        2.203e+00  6.136e-01  3.591 0.000421 ***
## citympg        -2.709e+02  1.642e+02 -1.649 0.100745
## highwaympg      1.522e+02  1.461e+02  1.042 0.298936
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2909 on 188 degrees of freedom
## Multiple R-squared:  0.8641, Adjusted R-squared:  0.854
## F-statistic: 85.38 on 14 and 188 DF, p-value: < 2.2e-16
```




Figure 6: Graphiques de diagnostic du modele nettoye

Interprétation : Le nettoyage a considérablement amélioré le modèle :

Indicateur	Modèle initial	Modèle nettoyé	Évolution
R^2	0,852	0,864	↑ +1 %
R^2 ajusté	0,841	0,854	↑
Erreur standard ($\hat{\sigma}$)	3 186 \$	2 909 \$	↓ meilleure précision
Statistique F	78,05	85,38	↑ modèle plus robuste

Le modèle explique désormais **86,4 %** de la variation du prix et prédit avec beaucoup plus de précision.

4.8 Graphique : Valeurs Observées vs Prédites




Figure 7: Valeurs Observees vs Predites – qualite d’ajustement global

Interprétation : Les points bleus sont très proches de la droite rouge (parfaite prédiction), surtout pour les prix entre 5 000 \$ et 20 000 \$. Pour les voitures très chères (au-delà de 30 000 \$), les points s’écartent un peu davantage, car le prix des voitures de luxe dépend de facteurs non capturés (prestige de marque, équipements).

4.9 Test de Normalité des Résidus (Shapiro-Wilk)




Figure 8: QQ-Plot des residus du modele nettoye

```
print(shapiro.test(residuals(reg_clean)))
```

```
##  
##  Shapiro-Wilk normality test  
##  
## data:  residuals(reg_clean)  
## W = 0.9821, p-value = 0.01095
```

Interprétation : Le test de Shapiro-Wilk teste H_0 : " les résidus suivent une loi normale ". Une p-value inférieure à 0,05 conduirait à rejeter H_0 par conséquent les erreurs ne suivent pas une loi normale. Une non-normalité partielle des résidus signifie que les tests statistiques doivent être interprétés avec prudence, mais n'invalide pas le modèle pour la prévision.

4.10 Vérification de l'Homoscédasticité




Figure 9: Residus vs Valeurs predites – verification de l'homoscedasticite

Interprétation : La répartition des points est suffisamment uniforme autour de la ligne $y = 0$ pour valider l'hypothèse d'**homoscédasticité** (variance constante des erreurs). Aucune transformation des données n'est nécessaire.

4.11 Intervalles de Confiance des Estimateurs MCO

L'intervalle de confiance à 95 % pour le coefficient β_j est :

$$\left[\hat{\beta}_j - t_{n-p-1, 0,025} \cdot \widehat{\text{se}}(\hat{\beta}_j) ; \hat{\beta}_j + t_{n-p-1, 0,025} \cdot \widehat{\text{se}}(\hat{\beta}_j) \right]$$

NB : si l'intervalle **ne contient pas 0**, la variable est statistiquement significative à 5 %.

```
print(round(confint(reg_clean, level = 0.95), 2))
```

```
##                2.5 %    97.5 %
## (Intercept)   -72780.12 -15519.80
## symboling     -246.75    645.78
## wheelbase     -30.93    357.48
## carlength     -207.72    -6.15
## carwidth       97.66    993.57
## carheight    -132.90    374.44
## curbweight     -1.80     4.47
## enginesize     100.46    152.37
## boreratio     -3889.36   484.50
## stroke        -5268.65 -2364.52
## compressionratio 178.62   481.69
## horsepower      3.77     62.39
## peakrpm         0.99     3.41
## citympg       -594.87    53.10
```

```
## highwaympg      -136.05    440.44
```

Interprétation :

- **Variables à effet positif** (intervalle entièrement > 0) : `carwidth`, `enginesize`, `compressionratio`, `horsepower`, `peakrpm`. Ces variables font **augmenter** le prix.
- **Variables à effet négatif** (intervalle entièrement < 0) : `carlength`, `stroke`. Ces variables font **baisser** le prix.
- **Variables non significatives** (intervalle contient 0) : `symboling`, `wheelbase`, `carheight`, `curbweight`, `boreratio`, `citympg`, `highwaympg`. Leur effet est trop incertain.

4.12 Variables Significatives au Seuil de 5 %

```
summary_clean <- summary(reg_clean)
var_sig <- summary_clean$coefficients[summary_clean$coefficients[, 4] < 0.05, ]
cat("Variables significatives au seuil de 5% :\n")
```

```
## Variables significatives au seuil de 5% :
```

```
print(round(var_sig, 4))
```

```
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -44149.9571 14513.4597 -3.0420  0.0027
## carlength    -106.9366   51.0911 -2.0931  0.0377
## carwidth      545.6165   227.0818  2.4027  0.0172
## enginesize     126.4191    13.1575  9.6081  0.0000
## stroke       -3816.5864   736.0952 -5.1849  0.0000
## compressionratio 330.1521   76.8181  4.2978  0.0000
## horsepower     33.0841    14.8585  2.2266  0.0272
## peakrpm        2.2033     0.6136  3.5909  0.0004
```

Interprétation : À un niveau de confiance de 95 %, les variables les plus solides statistiquement sont :

- **enginesize (+126,42 \$ par unité)** : prédicteur le plus puissant. Chaque unité supplémentaire de cylindrée augmente le prix d'environ 126,42 \$.
- **carwidth (+545,62 \$ par unité)** : une voiture plus large coûte nettement plus cher.
- **compressionratio (+330,15 \$ par unité)** : un moteur avec un taux de compression plus élevé justifie un prix plus important.
- **stroke (-3 816,59 \$ par unité)** : impact négatif le plus fort.

4.13 Prévisions sur 10 Nouvelles Observations

Il faut distinguer deux types d'intervalles :

- **Intervalle de confiance (espérance)** : fourchette pour le prix **moyen** de voitures ayant les mêmes caractéristiques.

$$IC_{\text{esp.}} : \hat{y}_0 \pm t_{n-p-1, \alpha/2} \cdot \hat{\sigma} \sqrt{\mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0}$$

- **Intervalle de prévision** : fourchette pour le prix **d'une voiture précise**. Il est plus large car il intègre la variabilité individuelle.

$$IC_{\text{prev.}} : \hat{y}_0 \pm t_{n-p-1, \alpha/2} \cdot \hat{\sigma} \sqrt{1 + \mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0}$$

```
new_obs <- df[196:205, names(df_quant)]
y_reel <- new_obs$price

ic_esp <- predict(reg_clean, newdata = new_obs, interval = "confidence", level = 0.95)
```

```
ic_prev <- predict(reg_clean, newdata = new_obs, interval = "prediction", level = 0.95)
mse_val <- mean((y_reel - ic_prev[, "fit"])^2)
cat("MSE :", round(mse_val, 0), "\n")
```

```
## MSE : 5186203
```

```
cat("RMSE :", round(sqrt(mse_val), 0), "$ (erreur moyenne par voiture)\n")
```

```
## RMSE : 2277 $ (erreur moyenne par voiture)
```

Interprétation : Le RMSE (2 277 \$) signifie que notre modèle se trompe en moyenne d'environ 2 277 \$ par voiture. Compte tenu d'une gamme de prix de 5 000 \$ à 45 400 \$, cette erreur est raisonnable.




Figure 10: Validation : Prix reels vs Prix predits avec intervalles de prevision

Interprétation : Toutes les croix bleues (prix réels) se situent à l'intérieur de la zone bleue (intervalle de prévision à 95 %). Le modèle ne s'est jamais trompé de façon absurde. La ligne noire suit fidèlement la tendance des prix réels, prouvant que notre équation de régression est utilisable pour fixer les prix des futurs modèles Geely Auto.

5 L'Analyse de la Variance (ANOVA)

5.1 Principe et Formulation Mathématique

L'ANOVA (*Analysis of Variance*) teste si une **variable qualitative** influence significativement la **moyenne** d'une variable quantitative. Elle décompose la variance totale :

$$SS_{\text{Total}} = SS_{\text{Inter}} + SS_{\text{Intra}}$$

où :

- $SS_{\text{Inter}} = \sum_{k=1}^K n_k (\bar{y}_k - \bar{y})^2$ est la variabilité **entre les groupes**,
- $SS_{\text{Intra}} = \sum_{k=1}^K \sum_{i=1}^{n_k} (y_{ik} - \bar{y}_k)^2$ est la variabilité **à l'intérieur des groupes**.

La statistique de test F rapporte ces deux sources :

$$F = \frac{SS_{\text{Inter}} / (K - 1)}{SS_{\text{Intra}} / (n - K)} \sim \mathcal{F}(K - 1, n - K) \quad \text{sous } H_0$$

Hypothèses : - H_0 : toutes les moyennes de groupes sont égales ($\mu_1 = \mu_2 = \dots = \mu_K$) - H_1 : au moins une moyenne de groupe diffère

5.2 Préparation et Quantités de l'ANOVA

```
data_anova <- df[, c("price", "doornumber")]
data_anova$doornumber <- as.factor(data_anova$doornumber)

nk <- as.numeric(table(data_anova$doornumber))
K <- length(nk)
n_tot <- sum(nk)
moyk <- as.numeric(tapply(data_anova$price,
                           data_anova$doornumber, mean))
moyt <- mean(data_anova$price)

cat("Effectifs par groupe      :", nk, "\n")

## Effectifs par groupe      : 115 90
cat("Moyennes par groupe      :", round(moyk, 0), "$\n")

## Moyennes par groupe      : 13501 12990 $
cat("Moyenne globale (directe) :", round(moyt, 0), "$\n")

## Moyenne globale (directe) : 13277 $
cat("Verification ponderee     :", round(sum(moyk * nk) / n_tot, 0), "$\n")

## Verification ponderee     : 13277 $
```

Interprétation : La concordance parfaite entre la moyenne globale et la moyenne pondérée des groupes (13 277 \$) valide l'intégrité mathématique de notre décomposition.

5.3 Analyse Graphique Exploratoire




Figure 11: Comparaison des prix selon le nombre de portes

Interprétation : Les deux boîtes sont quasiment à la même hauteur, avec des médianes très proches. Il semble *a priori* que le nombre de portes n'influence pas significativement le prix. Cependant, la présence de valeurs atypiques dans les deux groupes pourrait masquer une différence réelle. L'ANOVA va nous permettre de trancher statistiquement.

5.4 Lancement de l'ANOVA et Diagnostics

```
price.aov <- aov(price ~ doornumber, data = data_anova)
summary(price.aov)
```

```
##           Df    Sum Sq Mean Sq F value Pr(>F)
## doornumber   1 1.320e+07 13195198   0.206   0.65
## Residuals  203 1.301e+10 64071154
```

Sur l'échantillon complet, la p-value est supérieure à 0,05 : on ne rejette pas H_0 . En apparence, le nombre de portes **n'influence pas** le prix.




Figure 12: Diagnostics des résidus de l'ANOVA initiale

Interprétation : Ce graphique permet de vérifier la répartition des résidus. Les points sont organisés en deux bandes et la courbe de tendance est globalement horizontale, ce qui confirme la validité de l'hypothèse de linéarité. Le graphique Q-Q révèle des valeurs extrême (points 75, 17, 74 s'écartent de la droite) : les erreurs ne sont pas parfaitement normales à cause des véhicules de luxe. Ces points atypiques tirent artificiellement les moyennes vers le haut et **masquent une différence réelle** entre les groupes.

5.5 Nettoyage et ANOVA Finale

```
data_anova <- data_anova[-c(73, 74, 50), ]
rownames(data_anova) <- 1:nrow(data_anova)

anova_temp <- aov(price ~ doornumber, data = data_anova)
res_std <- rstandard(anova_temp)
prop_anova <- length(which(abs(res_std) > 2)) / nrow(data_anova) * 100
cat("Proportion residus hors-norme (|r| > 2) :", round(prop_anova, 2), "%\n")

## Proportion residus hors-norme (|r| > 2) : 6.93 %

a_supprimer <- which(abs(res_std) > 2.5)
data_anova_clean <- data_anova
if (length(a_supprimer) > 0) {
  data_anova_clean <- data_anova_clean[-a_supprimer, ]
  rownames(data_anova_clean) <- 1:nrow(data_anova_clean)
}

anova_final <- aov(price ~ doornumber, data = data_anova_clean)
summary(anova_final)

##              Df    Sum Sq  Mean Sq F value Pr(>F)
## doornumber    1 1.510e+08 151036411   5.434 0.0208 *
## Residuals   190 5.281e+09  27792991
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Interprétation : Après nettoyage, la p-value passe à 0,021 ($< 0,05$). **Le résultat s'inverse :** le nombre de portes est bien un facteur significatif du prix. Ce retournement illustre l'importance du nettoyage préalable

des données.

5.6 Comparaisons Multiples (Tests Post-Hoc)

5.6.1 Test de Tukey (HSD)

Le test de Tukey (HSD) est utilisé après une ANOVA afin de comparer les moyennes de plusieurs groupes deux à deux. Il permet d'identifier quelles catégories influencent significativement le prix des voitures.

Formule mathématique

$$q = \frac{|\bar{y}_i - \bar{y}_j|}{\sqrt{\frac{MSE}{n}}}$$

où :

- $\bar{y}_i, \bar{y}_j$: moyennes des groupes
- MSE : variance résiduelle
- n : taille des groupes

```
## Tukey multiple comparisons of means
## 95% family-wise confidence level
##
## Fit: aov(formula = price ~ doornumber, data = data_anova_clean)
##
## $doornumber
##          diff          lwr          upr      p adj
## two-four -1793.033 -3310.216 -275.8487 0.0207935
```




Figure 13: Test de Tukey – Intervalle de confiance de la difference de prix

Interprétation : La p-value étant inférieure à 0,05, la différence entre les voitures à deux portes et celles à quatre portes est statistiquement significative. la différence de prix entre les modèles 2 et 4 portes est de **-1 793 \$** (les 2 portes sont moins chères). L'intervalle de confiance à 95 % va de -3 310 \$ à -275 \$, **sans jamais passer par zéro**. Le graphique confirme ce résultat visuellement.

5.6.2 Test de Scheffé (Confirmation)

Le test de Scheffé est une méthode de comparaison multiple utilisée après une ANOVA. Il est plus conservateur que le test de Tukey et permet de confirmer la robustesse des différences observées entre les groupes.

Formule mathématique

$$F = \frac{(\bar{y}_i - \bar{y}_j)^2}{MSE \left(\frac{1}{n_i} + \frac{1}{n_j} \right)}$$

où :

- $\bar{y}_i, \bar{y}_j$: moyennes des groupes
- MSE : variance résiduelle
- n_i, n_j : tailles des groupes

```
if (!require(DescTools, quietly = TRUE)) install.packages("DescTools")
library(DescTools)
scheffe_test <- ScheffeTest(anova_final)
print(scheffe_test)
```

```
##
##   Posthoc multiple comparisons of means: Scheffe Test
##     95% family-wise confidence level
##
## $doornumber
##           diff      lwr.ci      upr.ci    pval
## two-four -1793.033 -3310.216 -275.8487 0.0208 *
##
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Interprétation : Le test de Scheffé, plus rigoureux, confirme exactement la même conclusion avec une p-value ajustée de 0,021. La **concordance parfaite** entre les deux tests valide définitivement l'existence d'un écart tarifaire significatif selon le nombre de portes. Pour Geely Auto, les véhicules à 4 portes peuvent être positionnés environ **1 793 \$ plus cher** que les modèles 2 portes.

6 Sélection de Facteurs (Optimisation du Modèle)

6.1 Recherche de Colinéarité (VIF)

La **multicolinéarité** survient quand des variables explicatives sont trop corrélées entre elles. Le **VIF** (*Variance Inflation Factor*) détecte ce problème :

$$VIF_j = \frac{1}{1 - R_j^2}$$

Un **VIF** > 10 signale une colinéarité problématique.

```
vif_results <- vif(reg_clean)
cat("=== VIF du modele nettoye (tries par ordre decroissant) ===\n")
```

```
## === VIF du modele nettoye (tries par ordre decroissant) ===
```

```
print(sort(vif_results, decreasing = TRUE))
```

```
##          citympg          highwaympg          curbweight          carlength
##          27.080605          23.736173          15.712591          9.360914
##          wheelbase          horsepower          enginesize          carwidth
##          8.435582          7.508026          6.281433          5.561843
##          carheight compressionratio          boreratio          peakrpm
##          2.311564          2.240256          2.154938          2.061116
##          symboling          stroke
##          1.905091          1.267847
```

Interprétation : citympg (VIF ~ 27) et highwaympg (VIF ~ 24) sont extrêmement redondantes. curbweight (VIF ~ 16) est déjà expliquée par les dimensions du véhicule.

Etape 1 : retrait de citympg

```
reg_v2 <- update(reg_clean, . ~ . - citympg)
cat("=== VIF apres retrait de citympg ===\n")
```

```
## === VIF apres retrait de citympg ===
```

```
print(sort(vif(reg_v2), decreasing = TRUE))
```

```
##          curbweight          carlength          wheelbase          horsepower
##          15.708334          8.553237          8.211811          6.784230
##          enginesize          highwaympg          carwidth          carheight
##          6.014582          5.634901          5.561701          2.310560
##          boreratio compressionratio          peakrpm          symboling
##          2.140814          2.108806          2.061113          1.860917
##          stroke
##          1.255425
```

Etape 2 : retrait de curbweight

```
reg_v3 <- update(reg_v2, . ~ . - curbweight)
cat("\n=== VIF apres retrait de curbweight (modele sain) ===\n")
```

```
##
```

```
## === VIF apres retrait de curbweight (modele sain) ===
```

```
print(sort(vif(reg_v3), decreasing = TRUE))
```

```
##          wheelbase          carlength          horsepower          carwidth
##          8.000054          7.956276          6.202204          5.434335
```

```
##      enginesize      highwaympg      carheight      boreratio
##      5.289571      4.371159      2.303816      2.140638
##      peakrpm      symboling compressionratio      stroke
##      1.992950      1.860674      1.733525      1.255397
```

Interprétation : Après deux suppressions ciblées, tous les VIF passent sous le seuil de 10. Le modèle `reg_v3` est désormais **sain** : chaque variable apporte une information propre et indépendante.

6.2 Sélection Pas-à-Pas (Stepwise – Critère AIC)

La méthode *stepwise* optimise automatiquement la composition du modèle selon le **critère AIC** :

$$AIC = -2\ln(\mathcal{L}) + 2p$$

Un AIC plus faible indique un meilleur compromis entre ajustement et complexité.

```
reg_final <- step(reg_v3, direction = "both", trace = 0)
cat("=== Resume du modele Stepwise ===\n")

## === Resume du modele Stepwise ===
summary(reg_final)

##
## Call:
## lm(formula = price ~ carwidth + enginesize + boreratio + stroke +
##      compressionratio + horsepower + peakrpm + highwaympg, data = df_quant2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -9145.2 -1531.8  -156.3   1645.5   9378.1
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -4.238e+04  1.269e+04  -3.340  0.001006 **
## carwidth      6.389e+02  1.694e+02   3.771  0.000216 ***
## enginesize    1.275e+02  1.186e+01  10.757 < 2e-16 ***
## boreratio     -1.753e+03  1.090e+03  -1.608  0.109538
## stroke       -3.780e+03  7.210e+02  -5.243  4.11e-07 ***
## compressionratio 3.334e+02  6.657e+01   5.008  1.23e-06 ***
## horsepower     3.739e+01  1.244e+01   3.007  0.002991 **
## peakrpm       2.121e+00  6.028e-01   3.519  0.000540 ***
## highwaympg    -8.572e+01  5.607e+01  -1.529  0.127941
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2922 on 194 degrees of freedom
## Multiple R-squared:  0.8585, Adjusted R-squared:  0.8526
## F-statistic: 147.1 on 8 and 194 DF, p-value: < 2.2e-16
```




Figure 14: Diagnostics du modèle Stepwise (AIC)

Interprétation : Les variables significatives ($p\text{-value} < 0,05$) sont :

- **carwidth** : effet positif $\rightarrow$ plus la voiture est large, plus le prix augmente
- **enginesize** : effet très fortement positif $\rightarrow$ facteur majeur du prix
- **stroke** : effet négatif $\rightarrow$ influence inverse sur le prix
- **compressionratio** : effet positif
- **horsepower** : effet positif $\rightarrow$ plus de puissance = prix plus élevé
- **peakrpm** : effet positif

Les variables non significatives :

- **boreratio**
- **highwaympg**

Elles pourraient être supprimées pour simplifier le modèle.

Qualité du modèle

- $R^2 = 0.8585 \rightarrow$ le modèle explique environ 85,85 % de la variabilité du prix
- R^2 ajusté = 0.8526 $\rightarrow$ modèle stable
- p-value globale $< 2.2 \times 10^{-16} \rightarrow$ modèle très significatif

La sélection par AIC a permis d'obtenir un modèle performant et relativement parcimonieux. Les variables liées aux caractéristiques du moteur (notamment *enginesize* et *horsepower*) sont les plus déterminantes dans l'explication du prix des voitures.

- Residuals vs Fitted : répartition aléatoire autour de 0 $\rightarrow$ homoscedasticité validée.
- Normal Q-Q : alignement imparfait sur la droite de Henry, mais acceptable pour $n > 50$ (TLC).
- Distance de Cook : aucune observation ne dépasse le seuil de 1 $\rightarrow$ pas de point influent majeur.
- Residuals vs Leverage : aucun point ne cumule résidu élevé et fort levier.

6.3 Recherche Exhaustive (regsubsets)

C'est une méthode qui teste toutes les combinaisons possibles de variables explicatives afin de trouver le modèle le plus performant. Elle permet d'identifier le sous-ensemble de variables qui explique le mieux la variable cible selon un critère choisi, puis comparons selon quatre critères :

Critère	Caractéristique
R^2 ajusté	Critère principal – pénalise la complexité
BIC	Très sévère – favorise les modèles simples
C_p de Mallows	Bon compromis biais/variance
R^2	Augmente toujours – non fiable seul

```
df_exhaustive <- reg_v3$model
best_models   <- regsubsets(price ~ ., data = df_exhaustive,
                             nvmax = ncol(df_exhaustive) - 1)
res_sum <- summary(best_models)

best_r2adj <- which.max(res_sum$adjr2)
best_bic   <- which.min(res_sum$bic)
best_cp    <- which.min(res_sum$cp)

cat("Nombre optimal de variables selon :", "\n")

## Nombre optimal de variables selon :
cat("  R2 ajuste  :", best_r2adj, "\n")

##   R2 ajuste   : 10
cat("   BIC       :", best_bic,   "\n")

##   BIC         : 6
cat("  Cp Mallows  :", best_cp,    "\n")

##  Cp Mallows   : 8
```




Figure 15: Selection exhaustive : variables retenues selon R2 ajuste, BIC et Cp de Mallows

Interprétation : Les cases noires indiquent les variables retenues à chaque niveau de complexité. **enginesize** et **carwidth** apparaissent **systématiquement** dans les meilleures configurations : ce sont les " piliers " du modèle. Le BIC retient 6 variables ; le C_p de Mallows en retient 8.

6.4 Modèle de Prédiction – Critère BIC (6 Variables)

Le **BIC (Bayesian Information Criterion)** est un critère utilisé pour sélectionner un modèle de régression. Il permet de comparer plusieurs modèles en tenant compte à la fois de la qualité d'ajustement et de la complexité du modèle.

L'objectif du BIC est de privilégier les modèles **simples et efficaces**, afin d'éviter le sur-apprentissage.

Le modèle retenu est celui qui possède la **valeur de BIC la plus faible**.

Formule du BIC :

$$BIC = -2\ln(L) + k \ln(n)$$

où : - L représente la vraisemblance du modèle - k est le nombre de paramètres du modèle - n est le nombre d'observations

Ainsi, le BIC permet de trouver un **compromis entre performance et simplicité**, ce qui améliore la capacité de généralisation du modèle.

```
reg_prev <- lm(price ~ carwidth + enginesize + stroke +
               compressionratio + horsepower + peakrpm,
               data = df_exhaustive)
summary(reg_prev)
```

```
##
## Call:
## lm(formula = price ~ carwidth + enginesize + stroke + compressionratio +
##     horsepower + peakrpm, data = df_exhaustive)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -8703.6 -1684.2  -132.4   1636.6  8999.7
##
## Coefficients:
```

```
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept)   -5.741e+04  9.983e+03  -5.751 3.36e-08 ***
## carwidth       7.120e+02  1.522e+02   4.677 5.41e-06 ***
## enginesize     1.277e+02  1.190e+01  10.726 < 2e-16 ***
## stroke        -3.587e+03  7.056e+02  -5.083 8.64e-07 ***
## compressionratio 2.983e+02  6.233e+01   4.786 3.35e-06 ***
## horsepower     3.784e+01  1.149e+01   3.294 0.00117 **
## peakrpm        2.396e+00  5.803e-01   4.128 5.40e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2938 on 196 degrees of freedom
## Multiple R-squared:  0.8555, Adjusted R-squared:  0.851
## F-statistic: 193.3 on 6 and 196 DF,  p-value: < 2.2e-16
```

Interprétation : Avec seulement 6 variables, ce modèle atteint un R^2 ajusté de 0.851. Toutes les variables sont hautement significatives (*). **Ce modèle est idéal pour des prévisions robustes**** sur de nouveaux véhicules car il évite le sur-apprentissage ou overfitting (est quand un modèle apprend trop bien les données d'entraînement, au point de mémoriser le détail et le bruit).

6.4.1 Analyse des Résidus du Modèle_prédiction




Figure 16: Diagnostics du modèle Prédiction (BIC)

Interprétation:

- Residuals vs Fitted (Linéarité) : On observe que les points sont répartis de manière assez homogène autour de la ligne horizontale zéro. La ligne rouge est relativement plate, ce qui confirme que la relation linéaire est bien respectée pour la majorité des véhicules.
- Normal QQ (Normalité des erreurs) : La plupart des points suivent parfaitement la ligne pointillée, ce qui indique que les erreurs du modèle suivent une loi normale. À noter toutefois que l'observation 127 s'écarte en haut à droite ; c'est une voiture dont le prix est plus difficile à prédire pour le modèle, mais cela reste acceptable.
- Scale-Location (Homoscédasticité) : Ce graphique montre que la dispersion des erreurs est à peu près constante sur toute la gamme de prix. Il n'y a pas d'effet « entonnoir » majeur, ce qui signifie que notre modèle est aussi précis pour les voitures économiques que pour les voitures plus chères.
- Residuals vs Leverage (Points influents) : C'est le point le plus rassurant : aucun point ne dépasse la zone critique de la distance de Cook (les lignes pointillées rouges en pointillé qu'on ne voit même pas ici car elles sont trop loin). Même si la voiture 127 a un certain levier, elle ne se déforme pas de manière inacceptable la pente de notre régression.

6.5 Modèle de Modélisation – Critère C_p de Mallows (8 Variables)

Le **critère C_p de Mallows** est un outil utilisé pour sélectionner un modèle de régression parmi plusieurs sous-modèles. Il permet d'évaluer la qualité d'un modèle tout en pénalisant sa complexité.

L'objectif est de choisir un modèle qui explique bien les données sans être trop complexe, afin d'éviter le sur-apprentissage.

Formule du critère C_p

$$C_p = \frac{RSS_p}{\hat{\sigma}^2} - (n - 2p)$$

où : - RSS_p est la somme des carrés des résidus du modèle contenant p variables - $\hat{\sigma}^2$ est une estimation de la variance de l'erreur - n est le nombre d'observations - p est le nombre de paramètres du modèle (variables + intercept)

Le critère C_p de Mallows permet donc de sélectionner un modèle optimal en trouvant un équilibre entre précision et simplicité, ce qui améliore la capacité de généralisation du modèle.

```
reg_model <- lm(price ~ wheelbase + carwidth + enginesize + stroke +
               compressionratio + horsepower + peakrpm + highwaympg,
               data = df_exhaustive)
summary(reg_model)
```

```
##
## Call:
## lm(formula = price ~ wheelbase + carwidth + enginesize + stroke +
##     compressionratio + horsepower + peakrpm + highwaympg, data = df_exhaustive)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -8931.5 -1566.1  -124.5   1637.8   9275.9
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   -48330.253   12079.047   -4.001 8.96e-05 ***
## wheelbase         52.299     66.214    0.790  0.4306
## carwidth        515.703    214.385    2.406  0.0171 *
## enginesize      125.125     12.133   10.312 < 2e-16 ***
## stroke        -3510.210    707.350   -4.962 1.52e-06 ***
## compressionratio  322.284     67.219    4.795 3.24e-06 ***
```

```
## horsepower      36.844      13.179      2.796      0.0057 **
## peakrpm         2.447       0.583      4.197 4.12e-05 ***
## highwaympg     -53.513      58.281     -0.918      0.3597
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2937 on 194 degrees of freedom
## Multiple R-squared:  0.857, Adjusted R-squared:  0.8511
## F-statistic: 145.4 on 8 and 194 DF, p-value: < 2.2e-16
```

Interprétation : Le R^2 ajusté est de 0.851, identique au modèle BIC. `wheelbase` et `highwaympg` ont des p-values individuelles $> 0,05$, mais le critère C_p les juge utiles pour stabiliser les prévisions globales et réduire le biais.

6.5.1 Analyse des Résidus du Modèle_modélisation




Figure 17: Diagnostics du modèle de modélisation (C_p)

Interprétation:

- Résidus vs Ajustés (Linéarité) : La ligne rouge montre une légère ondulation, mais elle reste globalement proche de l'axe zéro. Cela indique que le modèle linéaire capture l'essentiel de la tendance, même s'il existe une petite variabilité pour les voitures dont le prix est estimé autour de \$20 000 \$.
- Normal QQ (Normalité des résidus) : La majorité des points sont parfaitement alignés sur la diagonale. On observe cependant deux « files d'attente » : les points 100 (en bas) et 127 (en haut) s'écartent

un peu. Cela signifie que pour ces deux voitures spécifiques, le modèle fait une erreur un peu plus importante, mais cela ne remet pas en cause la normalité globale des erreurs.

- Scale-Location (Homoscédasticité) : La ligne rouge remonte légèrement, ce qui montre que l'erreur a tendance à être un peu plus grande pour les voitures les plus chères. C'est un phénomène classique sur le marché automobile où le prix des modèles de luxe est toujours plus difficile à stabiliser que celui des modèles de masse.
- Résidus vs Effet de levier (Points d'influence) : C'est le graphique le plus rassurant. On voit apparaître les pointillés de la Distance de Cook (seuil 0.5 et 1) .

6.6 Vérification Finale de la Colinéarité

La **colinéarité** apparaît lorsque plusieurs variables explicatives sont fortement corrélées entre elles. Cela peut poser problème dans un modèle de régression, car cela rend l'estimation des coefficients moins stable et moins interprétable.

L'objectif de cette vérification finale est de garantir que le modèle ne contient aucune variable redondante ou trop fortement liée aux autres.

Plusieurs outils peuvent être utilisés pour détecter la colinéarité :

- La matrice de corrélation entre les variables explicatives
- Le **VIF (Variance Inflation Factor)** :

$$VIF = \frac{1}{1 - R^2}$$

où R^2 est le coefficient de détermination obtenu en régressant une variable sur les autres.

Interprétation du VIF

- $VIF \approx 1$: pas de colinéarité
- $VIF > 5$: colinéarité modérée
- $VIF > 10$: forte colinéarité (problématique)

La vérification de la colinéarité permet d'améliorer la stabilité et la fiabilité du modèle final en supprimant ou en ajustant les variables fortement corrélées.

```
cat("=== VIF Modele BIC (6 variables) ===\n")

## === VIF Modele BIC (6 variables) ===
vif_bic <- vif(reg_prev)
print(sort(vif_bic, decreasing = TRUE))

##      enginesize      horsepower      carwidth      peakrpm
##      5.037027      4.397493      2.450035      1.806959
## compressionratio      stroke
##      1.445742      1.141976

cat("Toutes valeurs < 10 :", all(vif_bic < 10), "\n")

## Toutes valeurs < 10 : TRUE

cat("\n=== VIF Modele Cp Mallows (8 variables) ===\n")

##
## === VIF Modele Cp Mallows (8 variables) ===
```

```
vif_cp <- vif(reg_model)
print(sort(vif_cp, decreasing = TRUE))
```

```
##      horsepower      enginesize      carwidth      wheelbase
##      5.793797        5.239882        4.862713        3.743110
##      highwaympg      peakrpm      compressionratio      stroke
##      3.704080        1.825153        1.682667        1.148432
```

```
cat("Toutes valeurs < 10 :", all(vif_cp < 10), "\n")
```

```
## Toutes valeurs < 10 : TRUE
```

Interprétation : Les deux modèles finaux présentent des VIF bien inférieurs à 10. Il n'y a plus aucune multicollinéarité. Chaque variable conservée apporte une information **unique et fiable**.

6.7 Validation et Comparaison Finale des Modèles sur des nouvelles observations

L'objectif de cette étape est de mesurer l'erreur de prédiction sur de nouvelles observations en utilisant la RMSE (Root Mean Squared Error). La RMSE exprime l'erreur moyenne de prédiction directement en dollars (\$). Plus cette valeur est faible, plus le modèle est précis. **## Indicateur de Performance :** La RMSE Pour comparer nos modèles, nous utilisons la **RMSE** (*Root Mean Squared Error* ou Racine de l'Erreur Quadratique Moyenne).

La RMSE est définie par la formule suivante :

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Où : * n est le nombre de nouvelles observations. * y_i est le prix réel observé sur le marché américain. * $\hat{y}_i$ est le prix prédit par notre modèle mathématique.

```
## === Comparaison des performances ===
```

```
## Modele Cp Mallows (8 var) | RMSE : 2393 $
```

```
## Modele BIC (6 var) | RMSE : 2467 $
```

```
## Modele complet (14 var) | RMSE : 2277 $
```

Interprétation sur les 10 nouveaux observations: - **Précision maximale** : Le modèle complet (14 variables) affiche la RMSE la plus basse (2 277 \$). C'est logiquement le modèle qui colle le plus près aux données de test. - **Efficacité et Parcimonie** : Le modèle C_p de Mallows, avec seulement 8 variables, n'augmente l'erreur que de **116 \$** par rapport au modèle complet. Cela démontre que les 6 variables supplémentaires du modèle complet n'apportent qu'un gain marginal de précision. - **Simplicité extrême** : Le modèle BIC reste très compétitif avec une erreur de 2 467 \$, tout en étant le plus facile à interpréter commercialement.




Figure 18: Comparaison des prévisions : Modèle BIC (6 var) vs Modèle Cp Mallows (8 var)

Interprétation : Dans les deux graphiques, toutes les croix bleues se situent à l'intérieur de la zone bleue (intervalle de prévision à 95 %). Cette similitude prouve que les 6 variables sélectionnées par le BIC constituent le véritable cœur explicatif du prix. L'ajout de variables supplémentaires par le critère Cp de Mallows n'améliore pas visuellement la prédiction. Cela justifie mathématiquement notre préférence pour le modèle BIC : il offre la même fiabilité prédictive tout en étant plus simple (parcimonieux). Pour Geely Auto, cela démontre que la stratégie tarifaire peut être pilotée avec précision en se concentrant sur seulement 6 indicateurs clés.

Le tableau récapitulatif ci-dessous confirme que l'écart de précision entre les modèles est minime :

Modèle	Nb variables	R^2 ajusté	Erreur std. résidus ($\hat{\sigma}$)	RMSE prédiction	Multicolinéarité
Complet (Partie I)	14	0.841	~3 186 \$	2 277 \$	Non (après VIF)
C_p de Mallows	8	0.851	~2 937 \$	2 393 \$	Aucune
BIC	6	0.851	~2 938 \$	2 467 \$	Aucune

Le modèle *BIC* utilise **6 variables de moins** que le modèle complet pour une erreur de prédiction de seulement 2 467 \$ (vs 2 277 \$ pour le modèle complet, soit ~190 \$ de différence). Pour ceux qui souhaitent un meilleur équilibre biais/variance, le modèle C_p de Mallows (8 variables) reste une alternative valide. C'est le **meilleur compromis** précision/simplicité pour Geely Auto.

7 Conclusion Générale

7.1 Synthèse des Résultats

Cette étude a permis de construire un modèle statistique robuste pour prédire le prix des véhicules sur le marché américain. Voici les principaux enseignements :

Partie I – Régression Linéaire Multiple : Sans sélection de variables ni nettoyage, le modèle initial présentait une erreur standard des résidus de ~3 186 \$ (mesure d'ajustement sur l'échantillon). Sur les nouvelles observations, la RMSE de prédiction réelle du modèle complet est de **2 277 \$**. Après sélection des variables à l'aide du critère *BIC*, la RMSE de prédiction atteint **2 467 \$** avec seulement 6 variables, ce qui reste très compétitif. Le modèle *BIC* est privilégié car il est plus parcimonieux tout en conservant une excellente capacité prédictive. Pour ceux qui souhaitent davantage de variables, le modèle C_p de Mallows (8 variables, RMSE = 2 393 \$) constitue une alternative intermédiaire valide.

Partie II – ANOVA : L'analyse de la variance a révélé que le nombre de portes est un facteur de prix statistiquement significatif (p-value = 0,021 après nettoyage). Les véhicules à 4 portes se vendent en moyenne **1 793 \$ plus cher** que les modèles 2 portes.

Partie III – Sélection de Facteurs : Les variables les plus importantes pour prédire le prix sont, dans l'ordre : la **taille du moteur** (*enginesize*), la **largeur du véhicule** (*carwidth*), le **taux de compression** (*compressionratio*), la **puissance** (*horsepower*) et le **régime moteur** (*peakrpm*).

7.2 Recommandations pour Geely Auto

Le modèle final (*BIC*, 6 variables) est recommandé pour :

- Estimer le positionnement tarifaire d'un nouveau modèle Geely avec une marge d'erreur de ~2 467 \$ (RMSE de prédiction sur nouvelles observations) car il est plus parcimonieux tout en conservant une excellente précision
- Identifier les leviers d'action prioritaires : investir dans la cylindrée et la largeur du véhicule pour justifier des prix plus élevés
- Différencier les gammes : les modèles 4 portes peuvent être positionnés ~1 800 \$ plus chers

7.3 Limites du Modèle

Bien que le modèle *BIC* fournisse des prévisions précises, il suppose que la structure du marché reste stable. Des événements extérieurs comme une crise économique, de nouvelles normes environnementales ou l'essor des véhicules électriques pourraient modifier durablement les mécanismes de formation des prix. Par ailleurs, le modèle ne prend pas en compte des variables commerciales importantes comme le prestige de la marque ou les équipements intérieurs, ce qui limite sa capacité à expliquer les prix des véhicules de très grand luxe.