

PROJET

Consignes du projet

Avant toute chose, n'hésitez pas à venir me voir ou à me contacter par mail si vous avez un problème ou une question sur le projet. Voici un rappel de mon adresse mail : emmanuel.caron-partie@univ-avignon.fr. **Ne restez pas bloqué!** C'est un projet encadré; il faut interagir avec vos professeurs afin d'aller dans la bonne direction.

Ce projet est une application sur des données réelles des cours : "Introduction à la régression multiple" et "Modèle linéaire". Utilisez les ressources de ces cours.

Enfin, tout le matériel concernant cette SAE est disponible sur la page e-uapv intitulée "sae expliquer/predire une var. quanti. avec des facteurs (I-E05-3632)" (données, consignes, etc.).

Attention : je n'ai aucune envie de corriger le rapport d'une IA. Toute utilisation irréfléchie ou non nécessaire d'une IA sera sévèrement sanctionnée.

Introduction

- Le projet se fait seul ou par groupes de 2 étudiants.
- Le but principal est d'analyser les variations d'une variable d'un jeu de données en fonction des autres variables, grâce à l'application de modèles linéaires. Dans le cas des données sur la pollution dans les villes chinoises, il faut analyser les variations de la pollution d'une ville en fonction des autres variables.
- Pour le jeu de données vous pouvez : choisir des données sur internet (à faire valider par l'enseignant) ou utiliser les données chinoises sur l'e-uapv.
- Les objectifs de cette SAE sont multiples :
 - Préparer les données en vue d'une modélisation statistique
 - Prendre conscience de la différence entre modélisation statistique et analyse exploratoire (Utiliser les formules/graphes/etc. mathématiques et les interpréter)
 - Identifier différentes possibilités de modèles en vue de sélectionner le plus pertinent, notamment en fonction du type des variables étudiées
 - Appréhender l'idée de confronter une hypothèse avec la réalité pour prendre une décision
 - Apprécier les limites de validité et les conditions d'application d'un modèle
 - Savoir défendre ses choix d'analyses
 - Saisir la nécessité de choisir des indicateurs pertinents pour communiquer sur les résultats
 - Prendre conscience de la rigueur requise dans ses productions et dans la communication à leur propos
 - Réaliser l'importance de la mise en œuvre d'une procédure de test statistique pour valider ou non une hypothèse

Notations de la SAE

L'évaluation de cette SAE se fera sous la forme d'un rapport écrit. La notation se fera en rapport avec les trois compétences du BUT :

- C2 (Modéliser les données dans un cadre statistique) : Cela concernera principalement l'utilisation des modèles sur vos données et leur compréhension
- C3 (Valoriser une production dans un contexte professionnel) : Il sera évalué la qualité générale de votre rapport (qualité de la présentation, des explications, de l'analyse, etc.)
- C4 (Analyser statistiquement les données) : Cette partie prendra en compte la pertinence de vos analyses mathématiques.

Consigne pour le rapport

- Le rapport doit présenter et expliciter l'analyse de vos travaux permettant d'expliquer une variable Y en fonction des autres variables disponibles via des modèles linéaires, ainsi que l'interprétation (mathématique) de vos résultats.
- Le rapport doit être soignée, avoir un plan clair, et mettre clairement en avant les résultats principaux.
- Le rapport doit faire appel à des notions mathématiques élaborées vues en cours.
- Pensez à avoir une introduction et une conclusion. Dans l'introduction, présenter ce qui va être fait (les analyses mathématiques qui seront effectuées par exemple). La conclusion doit résumer les points importants et à retenir de votre analyse.
- Le fichier de code R devra m'être rendu et sera aussi pris en compte dans la notation. Il devra être bien **commenté** et **compiler sans erreur** (sinon la note est automatiquement divisée par 2).
Attention : les commandes R utilisées doivent être celles du cours et des TP. Toute utilisation de fonctions non étudiées en cours devra être dûment justifiée.
- Vos codes et analyses doivent évidemment être personnels. Ne copiez pas les uns sur les autres (cela se voit !) et ne faites pas de copier-coller sur le net.
- **Deadline : vendredi 10 avril 2026.**

Dans l'ensemble, ne vous contentez pas d'une analyse superficielle (ou descriptive) des données. Vous devez utiliser les statistiques et tous les outils des modèles pour justifier vos analyses. Interprétez statistiquement les résultats, et mettez à la fin en relation avec le phénomène étudié.

Le projet

Dans la suite, nous vous donnons quelques grandes lignes afin de vous guider lors de ce projet, et vous aiguiller sur les points que vous devez expliciter.

Vous utiliserez plusieurs modèles selon les différentes analyses. Il faudra à chaque fois ne considérer que les variables qui vous sont utiles.

Le projet se divise en trois parties (suivant plus ou moins l'ordre des cours correspondants).

Les consignes évolueront au fur et à mesure de la progression des cours. Regarder régulièrement ce document (mise à jour régulière sur l'e-uapv).

I Régression multiple

Pour la régression multiple, supprimez toutes les variables qui ne sont pas quantitatives avant de procéder à l'analyse.

- 1) Avant de commencer, effectuer une première analyse graphique du jeu de données avec la fonction `pairs`. Apercevez-vous des liaisons linéaires entre paires de variables ?
- 2) Procéder à la régression de votre variable Y sur les autres variables.
- 3) Interpréter les sorties du `summary` de la régression effectuée.
 - a) Que valent les estimateurs des moindres carrés ?
 - b) Leur estimation vous paraît-elle précise (regarder leur variance) ?
 - c) Que vaut le R^2 ? Commenter.
 - d) Que vaut la variance estimée des erreurs ?
 - e) Interpréter la statistique de test simultané (ou F-statistic) en dernière ligne du `summary`.
 - f) Le modèle linéaire semble-t-il pertinent pour l'étude de ces données ?
- 4) Procéder à l'analyse des résidus, en utilisant les graphiques vus en TP
 - a) Commencer par repérer les valeurs influentes et aberrantes et les supprimer une à une, en recommençant une nouvelle régression à chaque fois (penser à renommer le tableau de données à chaque fois avec la commande `rownames`, afin d'avoir toujours des noms de lignes entre 1 et n , où n est le nombre de données).
 - b) Une fois cela fait, éliminer les autres points aberrants. Un point peut-être considéré comme aberrant à partir du moment où son résidu standardisé est supérieur à 2 (ou inf. à -2). Cela correspond au quantile à 5% d'une variable gaussienne centrée réduite. Cela est évidemment à nuancer en fonction de la proportion de points qui vérifie cette condition.
Regarder le nombre de points dont le résidu standardisé (en valeur absolue) est supérieur à 2. En déduire la proportion du nombre de points potentiellement aberrants. Si cette proportion est inférieure à 5%, alors supprimer tous les points dont le résidu standardisé est bien supérieur à 2 (disons 3).
Vous pouvez ici supprimer plusieurs observations en même temps (ou même faire une boucle).
 - c) Ensuite, vérifier la normalité des résidus.
 - d) Enfin, vérifier le graphe des résidus en fonction des valeurs fittées. Procéder éventuellement à une transformation de BoxCox si nécessaire. Interpréter et commenter.
- 5) Refaire une analyse avec un `summary` et noter les améliorations (s'il y en a).
- 6) Afficher les intervalles de confiance des EMC. Commenter.
- 7) Avec le modèle complet, quelles sont les variables significatives au niveau 5% ? Commenter.
- 8) Afin d'effectuer des prévisions, chercher dans le jeu de données complet (sur l'e-uapv) 10 nouvelles données (par exemple les 10 valeurs qui suivent le bloc des données que vous avez choisi). Calculer les prévisions, les intervalles de confiance pour l'espérance de ces nouvelles valeurs ainsi que les intervalles de prévision. Commenter. Vous pouvez utiliser le MSE (Mean Squared Error) afin de quantifier la qualité de vos prévisions (cela servira notamment pour comparer avec le nouveau modèle que vous obtiendrez en section III (après la sélection de facteurs)).

II Anova

Dans cette partie, on étudiera les variations de la pollution en fonction de la direction du vent, afin de voir si cette dernière a une influence ou non. Si vous utilisez un autre jeu de données, il faudra alors étudier les variations de la variable quantitative choisie depuis le début en fonction d'une variable qualitative du jeu de données.

- 1) Construire un data-frame contenant la colonne de la variable à expliquer Y et celle de la variable explicative qualitative. Utiliser ce tableau de données pour cette section. Ne pas oublier de bien encoder vos variables au bon format.
Attention : Pour cette section, repartir de vos données initiales (votre bloc de données). On fera une analyse des résidus et on resupprimera les données aberrantes pour ce modèle.
- 2) Effectuer une première analyse graphique. Commenter.
- 3) Définir/calculer les quantités importantes du jeu de données pour l'Anova : le nombre de modalités K , les effectifs partiels n_k , les moyennes empiriques, etc.
- 4) Lancer l'Anova. Afficher la table de l'analyse de la variance. Interpréter.
- 5) Effectuer l'analyse des résidus. Re-procéder au nettoyage des données aberrantes.
- 6) Utiliser les méthodes de comparaisons multiples afin d'affiner votre analyse, et de localiser les différences. Vous pouvez utiliser la méthode de Tukey (cf. TP2 - Anova). Pour affiner/comparer vos résultats, vous pouvez utiliser la méthode de Scheffé (commande `ScheffeTest` du package `DescTools`).

III Régression multiple - Sélection de facteurs

Cette partie est la suite de la partie I. Reprendre les tableaux de données avec les variables quantitatives et les données que vous avez déjà nettoyées en partie I ; reprendre la régression que vous avez faite et repartir de là.

On veut effectuer une sélection de facteurs afin d'améliorer le modèle, que ce soit au niveau de la modélisation ou des prévisions.

N.B. : Vous pouvez trouver différents modèles après une sélection de facteurs, selon le critère choisi. N'hésitez pas à les présenter si c'est le cas, et à expliquer lesquels sont intéressants pour quelle(s) situation(s) (prévision, modélisation, etc.).

1. Effectuer une recherche de colinéarité entre les facteurs grâce au VIF. Interpréter.
2. Effectuer une première sélection de facteurs avec une méthode pas à pas backward ou forward, en fixant un critère (celui que vous voulez).
3. Après avoir fait une recherche exhaustive grâce à la commande `regsubsets`, utiliser les différents critères de sélection (BIC, C_p de Mallows, R^2 ajusté, ...) afin de sélectionner des modèles. Comparer les résultats.
4. Quel modèle choisir pour faire des prévisions ? Justifier.
5. Quel modèle choisir pour de la modélisation ? Justifier.
6. Ne pas oublier de refaire une analyse (rapide) de tous les modèles que vous obtenez (et que vous jugez pertinents) : analyser le `summary` de la régression des nouveaux modèles, vérifier les résidus, vérifier qu'il n'y a plus de colinéarité avec les VIFs, que les modèles sont adaptés, etc.

7. Refaire les prévisions de la fin de la partie I avec le(s) nouveau(x) modèle(s). Interpréter les résultats, comparer (avec le MSE par exemple) et conclure.